7 Técnicas multivariadas I (redução de dimensionalidade)

A redução de dimensionalidade se refere ao processo de reduzir o número de variáveis em um conjunto de dados, mantendo o máximo possível das informações originais. Existem várias razões pelas quais você pode querer reduzir a dimensionalidade dos dados:, dentre elas destacam-se:

- Eliminação de ruído e redundância (princípio da parcimônia);
- Simplificação e interpretabilidade;
- Visualização (projetar os dados em um espaço de menor dimensão).

Na literatura, existem duas abordagens principais para a redução de dimensionalidade:

- **Seleção de variáveis:** envolve selecionar um subconjunto das variáveis originais do conjunto de dados, consideradas as mais importantes para explicar a variabilidade nos dados;
- **Extração de variáveis:** as variáveis originais são transformadas em um novo conjunto de variáveis, geralmente de menor dimensão, que são combinações lineares das variáveis originais, escolhidas de forma a capturar a maior parte da variabilidade nos dados.

As abordagens de **extração de variáveis** serão o foco dos nossos estudos nessa seção e, dentre elas, vamos dicutir o método de Análise de Componentes Principais (PCA) e o método de Análise Fatorial (AF).

7.1 Análise de componentes principais

7.1.1 Conceitos iniciais

A **Análise de Componentes Principais (ACP)**, inicialmente proposta por Karl Pearson em 1901 e estudada e nomeada por Harold Hotelling em 1933, é uma técnica que transforma linearmente um conjunto de p variáveis correlacionadas em um conjunto de p variáveis não correlacionadas.

Essa transformação nos permite que, ao invés de trabalhar com p variáveis, seja possível trabalhar com somente k dessas variáveis, tal que $k < p$, que são capazes de explicar uma parcela substancial das informações do conjunto original de p variáveis.

Os objetivos ao se usar a ACP são:

- Redução de dimensionalidade (variáveis não correlacionadas);
- Obter combinações interpretáveis das variáveis originais;
- Descrever e/ou compreender a estrutura de correlação das variáveis originais.

$p \to 100\%$

$K \to 70\% - 90\%$

$p = 10$

$K = 7 \quad K = 2 \quad \dots$

7.1.2 Contexto estatístico

Nessa seção, vamos estudar a ACP sob o ponto de vista estatístico, ou seja, ACP que tenham propriedades estatísticas. Assim, vamos considerar que se as variáveis originais tiverem distribuição normal multivariada, as componentes principais serão independentes entre si e também terão distribuição normal multivariada.

Para explanação dos conceitos durante nossos estudos, vamos seguir duas abordagens de obtenção das componentes principais:

- Obtenção das componentes principais a partir da matriz de covariância (populacional e amostral);
- Obtenção das componentes principais a partir da matriz de correlação (populacional e amostral).

Assim, seja $\mathbf{X}_{p\times 1}$ um vetor aleatório com vetor de médias (populacionais) $\boldsymbol{\mu}_{p\times 1}$ e matriz de variâncias e covariâncias (populacionais) $\boldsymbol{\Sigma}_{p\times p}$. Estamos particularmente interessados no caso em que as variáveis $\mathbf{X}_1, ..., \mathbf{X}_p$ estão correlacionadas, isto é, existe $\mathrm{Cov}(X_i, X_j)$ não-nulas, para $i, j = 1, ..., p$ e $i \neq j$. Graficamente, podemos representar esse questionamento da seguninte forma:

$$\underset{\sim}{X}_{p\times 1} = [\underset{\sim}{X}_1 \quad \underset{\sim}{X}_2 \quad \dots \quad \underset{\sim}{X}_p]$$

$$= \begin{bmatrix} X & X & & X \\ X & X & \dots & X \\ X & X & & X \end{bmatrix} \leftarrow \text{MATRIZ}$$

$$\mu = (\bullet \quad \bullet \quad \dots \quad \bullet), \quad \Sigma_{p\times p} = \begin{pmatrix} Cov X_1, X_1 \\ Cov X_2, X_1 \\ ? \end{pmatrix}$$

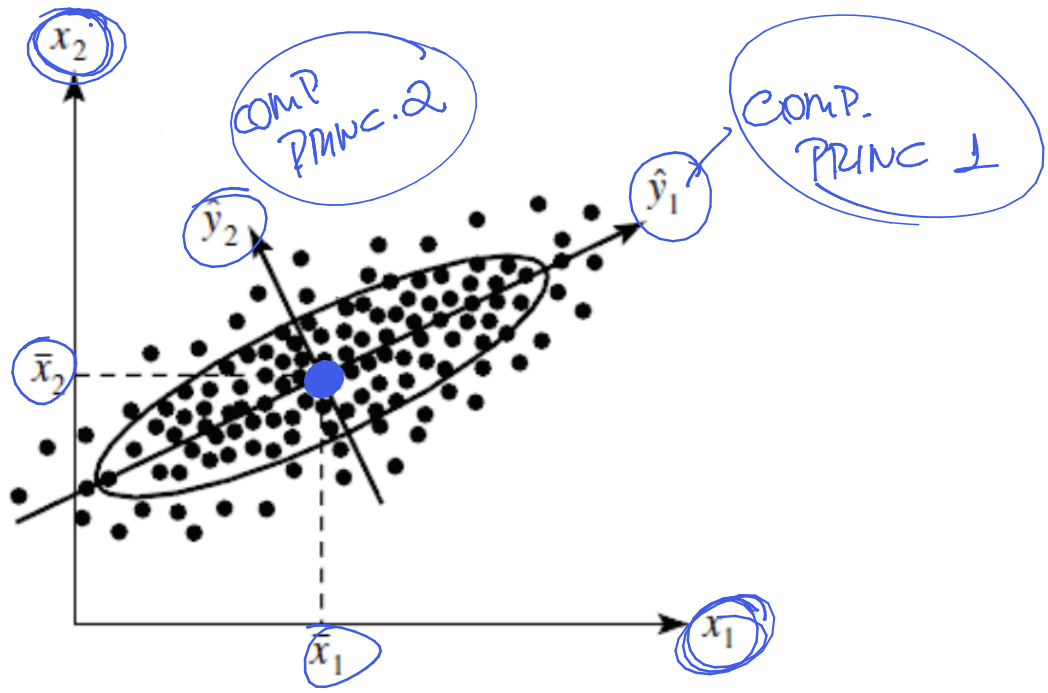

Figure 1: Representação gráfica da ACP.

Quando isso ocorre, existe redundância entre dimensões e podemos ter interesse em reduzir a dimensionalidade do problema, construindo novas variáveis, não correlacionadas entre si, que sejam **combinações lineares das variáveis originais**.

Pode ser que poucas (k) novas variáveis expliquem grande parte da variabilidade existente nas (p) variáveis originais. Isso pode significar a redução de custos como tempo computacional e espaço para armazenamento de dados.

7.1.3 ACP via matriz de covariância

Seja $\mathbf{X}_{p\times 1}$ um vetor aleatório com vetor de médias (populacionais) $\boldsymbol{\mu}_{p\times 1}$ e matriz de covariâncias (populacionais) $\boldsymbol{\Sigma}_{p\times p}$ que segue uma distribuição qualquer, que denotamos por $\mathbf{X} \sim (\boldsymbol{\mu}, \boldsymbol{\Sigma})$.

A ideia da **ACP via matriz de covariância** é decompor a matriz $\boldsymbol{\Sigma}$ em autovalores e autovetores, tais $\lambda_1, \lambda_2, ..., \lambda_p$ são os seus autovalores e $\mathbf{e}_1, \mathbf{e}_2, ..., \mathbf{e}_p$ são os seus autovetores, que obedecem às seguintes condições:

- $\lambda_1 \geq ... \geq \lambda_p$;
- $\mathbf{e}_i^\top \mathbf{e}_j = 0$, $i, j = 1, ..., p$ e $i \neq j$ (os vetores são ortogonas entre si);
- $\mathbf{e}_i^\top \mathbf{e}_i = 1$, $i, j = 1, ..., p$;
- $\boldsymbol{\Sigma}\mathbf{e}_i = \lambda_i \mathbf{e}_i$, $i, j = 1, ..., p$.

Σ

λ e

Para isso, considere a matriz ortogonal $\mathbf{O}_{p\times p}$, tal que $\mathbf{O} = (\mathbf{e}_1, \mathbf{e}_2, ..., \mathbf{e}_p)$ é um matriz formada pelos autovetores de $\boldsymbol{\Sigma}$. Então, podemos reescrever $\mathbf{Y}_{p\times 1}$ de tal forma que

$$\mathbf{Y}_{p\times 1} = \mathbf{O}_{p\times p}^\top \mathbf{X}_{p\times 1},$$

y_1 y_2 y_p

$y =$

λ_1 λ_2 λ_p

$\lambda_1 + \lambda_2 + \lambda_3 \cong 80\%$ $\quad e_1\ e_2\ e_3 \to 0$

que obedece ao fato de que $\mathbf{e}_1$ é o autovetor correspondente ao maior autovalor de $\boldsymbol{\Sigma}$ (dado por λ_1), $\mathbf{e}_2$ é o autovetor correspondente ao segundo maior autovalor de $\boldsymbol{\Sigma}$ (dado por λ_2) e assim sucessivamente.

Ou seja, cada componente principal será uma combinação linear dos elementos de $\mathbf{X}$, mas as entradas da combinação linear são os elementos dos autovetores correspondentes aos autovalores de $\boldsymbol{\Sigma}$.

Essa decomposição apresenta as seguintes propriedades:

Y_1 $\quad \frac{\lambda_1}{\sum_{i=1}^{p} \lambda_i}$ $\quad \lambda_1$

- A j-ésima componente principal de $\boldsymbol{\Sigma}$ é dada por $\mathbf{Y}_j = \mathbf{e}_j^\top \mathbf{X}$;
- $\mathbb{E}(\mathbf{Y}_j) = \mathbb{E}(\mathbf{e}_j^\top \mathbf{X}) = \mathbf{e}_j^\top \mathbb{E}(\mathbf{Y}_j) = \mathbf{e}_j^\top \boldsymbol{\mu}$;
- $\mathrm{Var}(\mathbf{Y}_j) = \mathrm{Var}(\mathbf{e}_j^\top \mathbf{X}) = \mathbf{e}_j^\top \boldsymbol{\Sigma} \mathbf{e}_j = \lambda_j \mathbf{e}_j^\top \mathbf{e}_j = \lambda_j$;
- $\mathrm{Cov}(\mathbf{Y}_i, \mathbf{Y}_j) = \mathrm{Cor}(\mathbf{Y}_i, \mathbf{Y}_j) = 0$, $i, j = 1, ..., p$ e $i \neq j$;
- A proporção da variância total de $\mathbf{X}$ e que é explicada pela j-ésima componente principal é $\dfrac{\lambda_j}{\sum_{i=1}^{p} \lambda_i}$.

Porém, como em geral a matriz $\boldsymbol{\Sigma}$ é desconhecida, utiliza-se a matriz $\mathbf{S}$, de covariâncias amostrais, para estimar as componentes principais. A ideia é a mesma, ou seja, decompor a matriz $\mathbf{S}$ em autovalores e autovetores, tais $\hat{\lambda}_1, \hat{\lambda}_2, ..., \hat{\lambda}_p$ são os seus autovalores e $\hat{\mathbf{e}}_1, \hat{\mathbf{e}}_2, ..., \hat{\mathbf{e}}_p$ são os seus autovetores, que obedecem às seguintes propriedades:

$Y_j = e_j X$

- A j-ésima componente principal de $\mathbf{S}$ é dada por $\boxed{\hat{\mathbf{Y}}_j = \hat{\mathbf{e}}_j^\top \mathbf{X};}$
- $\mathrm{Var}(\hat{\mathbf{Y}}_j) = \mathrm{Var}(\hat{\mathbf{e}}_j^\top \mathbf{X}) = \hat{\mathbf{e}}_j^\top \boldsymbol{\Sigma} \hat{\mathbf{e}}_j = \hat{\lambda}_j \hat{\mathbf{e}}_j^\top \hat{\mathbf{e}}_j = \hat{\lambda}_j$;
- $\mathrm{Cov}(\hat{\mathbf{Y}}_i, \hat{\mathbf{Y}}_j) = \mathrm{Cor}(\hat{\mathbf{Y}}_i, \hat{\mathbf{Y}}_j) = 0$, $i, j = 1, ..., p$ e $i \neq j$;
- A proporção da variância total de $\mathbf{X}$ e que é explicada pela j-ésima componente principal é $\dfrac{\hat{\lambda}_j}{\sum_{i=1}^{p} \hat{\lambda}_i}$;

É comum utilizar os escores das componentes para análises estatísticas ou ordenação (ranking) dos elementos amostrais. Esses escores são obtidos ordenando os valores obtidos de

$$\hat{\mathbf{Y}}_j = \hat{\mathbf{e}}_j^\top \mathbf{X}.$$

$\to X_1 \in [0,1]$

$\to X_2 \in [0,1]$

$\to X_3 \in [-\infty, \infty]$

7.1.4 ACP via matriz de correlação

Caso esteja lidando com variáveis que tenham magnitude diferente e não queremos que isso influencie nos resultados, usamos a decomposição a partir da matriz de correlação dos dados (às vezes pode ser de interesse manter essas variáveis, a fim de estudar o comportamento dessas variáveis com maior variabildade).

$X_1 \quad X_2 \quad X_p$

$X \sim N(\mu, \sigma^2) \Longrightarrow \boxed{Z = \frac{X-\mu}{\sigma}} \sim N(0,1)$

DISTRIBUIÇÃO

Seja $\mathbf{X}_{p\times 1}$ um vetor aleatório com vetor de médias (populacionais) $\boldsymbol{\mu}_{p\times 1}$ e matriz de covariâncias (populacionais) $\boldsymbol{\Sigma}_{p\times p}$, denotado por $\mathbf{X} \sim (\boldsymbol{\mu}, \boldsymbol{\Sigma})$. A ideia da **ACP via matriz de correlação** consiste em padronizar cada variável X_i na forma

$$\boxed{Z_i = \frac{X_i - \mu_i}{\sigma_i},}$$

sendo $Z = (Z_1, ..., Z_p)^\top$, em que $\mu_i = \mathbb{E}(X_i)$ e $\sigma_i^2 = \mathrm{Var}(X_i)$, tal que $\mathrm{Cov}(\mathbf{Z}) = \mathbf{P} = \mathrm{Cor}(X)$, e decompor a matriz $\mathbf{P}$ em autovalores e autovetores, tais $\lambda_1, \lambda_2, ..., \lambda_p$ são os seus autovalores e $\mathbf{e}_1, \mathbf{e}_2, ..., \mathbf{e}_p$ são os seus autovetores, que obedecem às seguintes condições:

$\Sigma \to P$

- $\lambda_1 \geq ... \geq \lambda_p$;
- $\mathbf{e}_i^\top \mathbf{e}_j = 0$, $i, j = 1, ..., p$ e $i \neq j$ (os vetores são ortogonas entre si);
- $\mathbf{e}_i^\top \mathbf{e}_i = 1$, $i, j = 1, ..., p$;
- $\mathbf{P}\mathbf{e}_i = \lambda_i \mathbf{e}_i$, $i, j = 1, ..., p$.

$X \to Z$

Para isso, considere a matriz ortogonal $\mathbf{O}_{p\times p}$, tal que $\mathbf{O} = (\mathbf{e}_1, \mathbf{e}_2, ..., \mathbf{e}_p)$ é um matriz formada pelos autovetores de $\mathbf{P}$. Então, podemos reescrever $\mathbf{Y}_{p\times 1}$ de tal forma que

$$\mathbf{Y}_{p\times 1} = \mathbf{O}_{p\times p}^\top \mathbf{Z}_{p\times 1},$$

X PADRONIZAÇÃO

que obedece ao fato de que $\mathbf{e}_1$ é o autovetor correspondente ao maior autovalor de $\mathbf{P}$ (dado por λ_1), $\mathbf{e}_2$ é o autovetor correspondente ao segundo maior autovalor de $\mathbf{P}$ (dado por λ_2) e assim sucessivamente.

Ou seja, cada componente principal será uma combinação linear dos elementos de $\mathbf{X}$, mas as entradas da combinação linear são os elementos dos autovetores correspondentes aos autovalores de $\mathbf{P}$.

Essa decomposição apresenta as seguintes propriedades:

$\frac{\lambda_j}{P}$

- A j-ésima componente principal de $\mathbf{P}$ é dada por $\mathbf{Y}_j = \mathbf{e}_j^\top \mathbf{Z}$;
- $\mathbb{E}(\mathbf{Y}_j) = \mathbb{E}(\mathbf{e}_j^\top \mathbf{X}) = \mathbf{e}_j^\top \mathbb{E}(\mathbf{Y}_j) = \mathbf{e}_j^\top \boldsymbol{\mu}$;
- $\mathrm{Var}(\mathbf{Y}_j) = \mathrm{Var}(\mathbf{e}_j^\top \mathbf{X}) = \mathbf{e}_j^\top \boldsymbol{\Sigma} \mathbf{e}_j = \lambda_j \mathbf{e}_j^\top \mathbf{e}_j = \lambda_j$;
- $\mathrm{Cov}(Y_i, Y_j) = \mathrm{Cor}(Y_i, Y_j) = 0$, $i, j = 1, ..., p$ e $i \neq j$;

$\begin{pmatrix} 1 & & & \\ & 1 & & \\ & & \ddots & \\ & & & 1 \end{pmatrix}$ P

- A proporção da variância total de $\mathbf{Z}$ e que é explicada pela j-ésima componente principal é $\frac{\lambda_j}{p}$ (na matriz de correlação, a diagonal principal é formada por uns, então como temos p variáveis, temos p no denominador).

Porém, como em geral a matriz $\mathbf{P}$ é desconhecida, utiliza-se a matriz $\mathbf{R}$, de correlações amostrais, para estimar as componentes principais. Nesse caso, teremos as seguintes propriedades:

- A j-ésima componente principal de $\mathbf{R}$ é dada por $\hat{\mathbf{Y}}_j = \hat{\mathbf{e}}_j^\top \mathbf{Z}$;

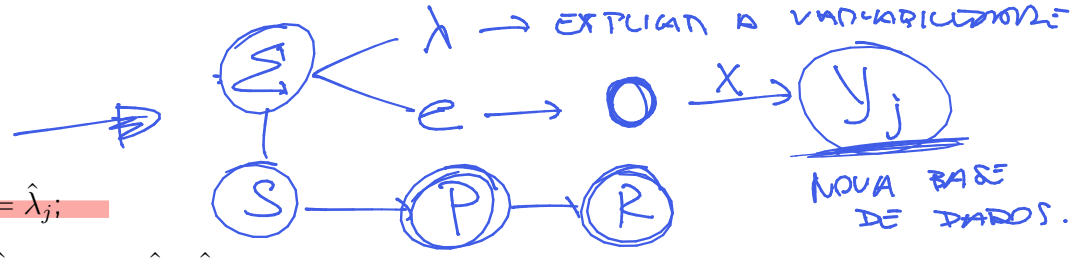

- $\mathrm{Var}(\hat{\mathbf{Y}}_j) = \hat{\lambda}_j$;
- $\mathrm{Cov}(\hat{\mathbf{Y}}_i, \hat{\mathbf{Y}}_j) = \mathrm{Cor}(\hat{\mathbf{Y}}_i, \hat{\mathbf{Y}}_j) = 0$, $i, j = 1, ..., p$ e $i \neq j$;
- A proporção da variância total de $\mathbf{X}$ e que é explicada pela j-ésima componente principal é $\dfrac{\hat{\lambda}_j}{p}$;

É comum utilizar os escores das componentes para análises estatísticas ou ordenação (ranking) dos elementos amostrais. Esses escores são obtidos ordenando os valores obtidos de

$$\hat{\mathbf{Y}}_j = \hat{\mathbf{e}}_j^\top \mathbf{Z}.$$

7.1.5 Determinação do número de componentes principais

OBJ
- Proporção da variância total explicada; λ → AUTO VALOR.
- Análise gráfica da variância explicada (scree-plot ou gráfico de cotovelo);

SUBJ
- Análise prática das componentes principais.

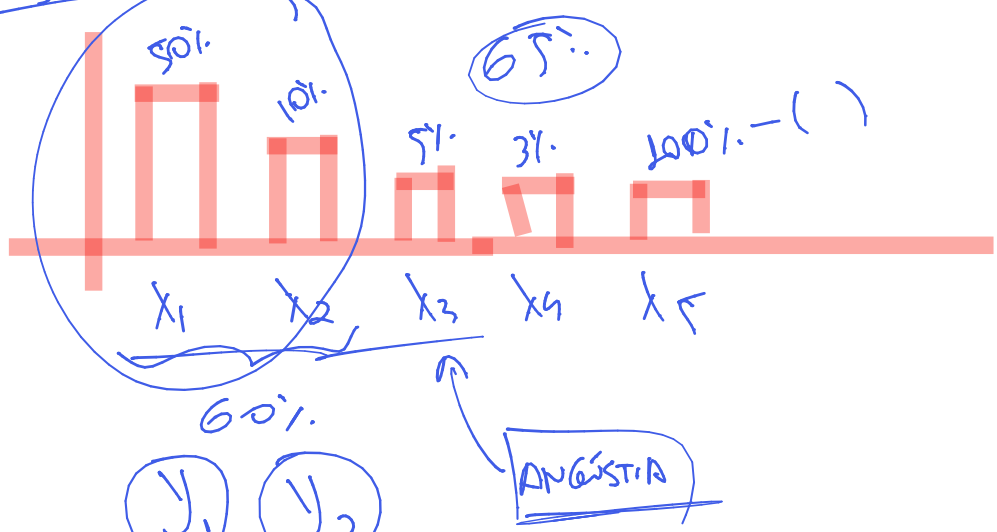

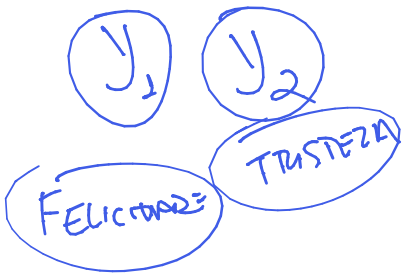

PAUSA !! 0,0

7.2 Análise Fatorial

7.2.1 Conceitos iniciais

$\Sigma \to$ COV
$P \to$ COR

Assim como a Análise de componentes principais, a **Análise Fatorial (AF)**, proposta por Charles Spearman em 1904, também é uma técnica de redução de dimensionalidade de acordo com a variabilidade original do vetor aleatório $\mathbf{X}_{p\times 1}$ em termos de um número menor m de variáveis aleatórias, mas cujas componentes, chamadas de fatores comuns, são variáveis latentes, que estão relacionadas com $\mathbf{X}$ por meio de um modelo linear.

Os objetivos da AF são:

COMPONENTE (ACP)

- Agrupar as variáveis originais de $\mathbf{X}_i$, $i = 1, .., p$, em fatores mutuamente não correlacionados e interpretáveis;

  FATOR (AF)

- Reduzir a dimensionalidade do problema.

Além disso, vale ressaltar que essa técnica é divida em duas diferentes abordagens:

- Análise Fatorial $\boxed{\text{Exploratória}}$ (AFE); → NÃO TEM INFO
- Análise Fatorial Confirmatória (AFC). → TEM INFO

TBM PODEMOS P/ Σ.

7.2.2 Estrutura

Sejam $\mathbf{X}_{p\times 1}$ um vetor aleatório com $\mathbb{E}(\mathbf{X}) = \boldsymbol{\mu}$, $\mathrm{Var}(\mathbf{X}) = \boldsymbol{\Sigma}$, $\mathrm{Cor}(\mathbf{X}) = \mathbf{P}$ e

$X \to Z$

$$Z_i = \frac{X_i - \mu_i}{\sigma_1}, \quad \sigma_1 \to \sigma_i$$

$$\boxed{P \cdot b = \lambda \cdot b}$$

para $i = 1, ..., p$ tal que $\mathrm{Cov}(\mathbf{Z}) = \mathbf{P} = \mathrm{Cor}(\mathbf{X})$

Queremos explicar as variáveis padronizadas $\mathbf{Z}_1, ..., \mathbf{Z}_p$ com m fatores $\mathbf{F}_1, ..., \mathbf{F}_m$, de tal forma que:

$$\mathbf{Z} = \mathbf{LF} + \boldsymbol{\epsilon},$$

$$y = X\beta + \varepsilon$$

BASE DE DADOS

$$L \quad F + \varepsilon$$

NÃO SEI EXPLICAR

cuja estrutura matricial pode ser apresentada pela seguinte expressão

$$\begin{aligned}
\mathbf{Z}_1 &= l_{11}\mathrm{F}_1 + ... + l_{1m}\mathrm{F}_m + \epsilon_1 \\
\mathbf{Z}_2 &= l_{21}\mathrm{F}_1 + ... + l_{2m}\mathrm{F}_m + \epsilon_2 \\
&\vdots \\
\mathbf{Z}_p &= l_{p1}\mathrm{F}_1 + ... + l_{pm}\mathrm{F}_m + \epsilon_p,
\end{aligned}$$

sendo

- $\mathbf{F}_{m\times 1}$ um vetor aleatório que contém m fatores (também chamados de variáveis latentes, que descrevem os elementos da população e são não observáveis);
- $\boldsymbol{\epsilon}$ o vetor de erros aleatórios não observáveis (o que não conseguimos explicar);

$Z = LF + \varepsilon$ → COEF. DA COMB. LINEAR

- l_{ij}, também chamado de loading (peso) ou carga fatorial, o coeficiente da i-ésima variável padronizada Z_i, $i = 1, ..., p$ no j-ésimo fator, F_j , $j = 1, ..., m$ e $\mathbf{L}$ é a matriz de cargas fatoriais.

O modelo $\boxed{\mathbf{Z} = \mathbf{L}\mathbf{F} + \boldsymbol{\epsilon}}$ é chamado de modelo fatorial ortogonal, já que os m fatores são ortogonais entre si. Essa estrutura apresenta as seguintes suposições:

- $\mathbb{E}(\mathbf{F}) = \mathbf{0}$;
- $\mathrm{Var}(\mathbf{F}) = \mathbf{I}$;
- $\mathbb{E}(\boldsymbol{\epsilon}) = \mathbf{0}$;
- $\mathrm{Var}(\boldsymbol{\epsilon}) = \boldsymbol{\Psi} = \mathrm{diag}(\Psi_1, ..., \Psi_p)$.
- $\mathbf{F}$ e $\boldsymbol{\epsilon}$ são não correlacionados

$y = X\beta + \varepsilon$ → $Var(\varepsilon) = \Psi$ $\quad E(\varepsilon) = 0$ $\quad \sim N$

$y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$

$y - X\beta = \varepsilon$

máxima verossim.

O objetivo dessa abordagem é, portanto, decompor a matriz $\mathbf{P}$ na forma

$$\mathbf{P} = \mathbf{L}_{p\times m}\mathbf{L}^{\top}_{m\times p} + \boldsymbol{\Psi}_{p\times p},$$

↳ COMUNALIDADES ENTRE OMAS

cuja representação é dada por

$$\boxed{\mathbf{P} = \mathbf{L}\mathbf{L}^{\top} + \boldsymbol{\Psi}} = \begin{pmatrix} \sum_{j=1}^{m} l_{1j}^2 & \cdots & \sum_{j=1}^{m} l_{1j}l_{jp} \\ \vdots & \ddots & \vdots \\ \sum_{j=1}^{m} l_{pj}l_{j1} & \cdots & \sum_{j=1}^{m} l_{pj}^2 \end{pmatrix} + \begin{pmatrix} \Psi_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ \vdots & \cdots & \Psi_p \end{pmatrix}.$$

Assim, vem que:

- $\mathrm{Var}(Z_i) = \sum_{j=1}^{m} l_{ij}^2 + \Psi_i = h_i^2 + \Psi_i = 1$, em que h_i^2 é chamado comunalidade (devido aos fatores) e Ψ_i é chamado de variância específica

Pode-se estimar $\mathbf{L}$ e $\boldsymbol{\Psi}$ utilizando alguns métodos, dentre eles:

- Método das componentes principais ou fatores principais;
- Método das componentes principais iterativo ou fatores principais iterativo;
- Método da máxima verossimilhança (com a suposição de normalidade).

7.2.3 Estimação do modelo usando o método da máxima verossimilhança

Suponha que $\mathbf{X} \sim \mathcal{N}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ e, portanto, $\mathbf{Z} \sim \mathcal{N}_p(\mathbf{0}, \mathbf{P})$. Além disso, $\mathbf{F} \sim \mathcal{N}_p(\mathbf{0}, \mathbf{I})$ e $\boldsymbol{\epsilon} \sim \mathcal{N}_p(\mathbf{0}, \boldsymbol{\Psi})$.

A função de verossimilhança considerando uma amostra aleatória de tamanho n, $\mathbf{Z}_1, ..., \mathbf{Z}_n$, é expressa por

$$\boxed{L(P) = \frac{1}{(2\pi)^{np/2}|P|^{n/2}} \exp\left(-\frac{1}{2}\sum_{j=1}^{n} \mathbf{z}_j^{\top} P^{-1} \mathbf{z}_j\right),}$$

Σ $\quad \Sigma$

$(x-\mu)^T \Sigma^{-1} (x-\mu)$

$y = \beta_0 + \beta_1 X$

$U_{\beta_0} = \frac{\partial L}{\partial \beta_0} = 0 \rightarrow \hat{\beta}_0 \qquad U_{\beta_1} = \frac{\partial L}{\partial \beta_1} = 0 \rightarrow \hat{\beta}_1$

ou seja,

$$L(P) = \frac{1}{(2\pi)^{np/2}|\mathbf{L}\mathbf{L}^\top + \mathbf{\Psi}|^n/2} \exp\left(-\frac{1}{2}\sum_{j=1}^{n} \mathbf{z}_j^\top (\mathbf{L}\mathbf{L}^\top + \mathbf{\Psi})^{-1}\mathbf{z}_j\right),$$

e devemos encontrar o máximo de $L(P)$ em $\mathbf{L}$ e $\mathbf{\Psi}$. Essa maximização é feita em termos numéricos para um valor de m fixo (o algoritmo pode não convergir e outro método pode ser considerado).

Se a suposição de normalidade é válida, o método da máxima verossimilhança pode produzir estimativas mais precisas. Se não podemos supor a normalidade multivariada, convém utilizar o método de fatores principais ou fatores principais iterativo. Vale ressaltar que diferentes valores de m podem levar a diferentes estimativas das cargas fatoriais.

7.2.4 Rotação ortogonal de fatores

Podemos estar interessado em aplicar transformações ortogonais aos fatores originais de modo que os novos fatores obtidos tenham interpretações mais fáceis e diretas. Graficamente, estamos interessados em fazer a seguinte rotação:

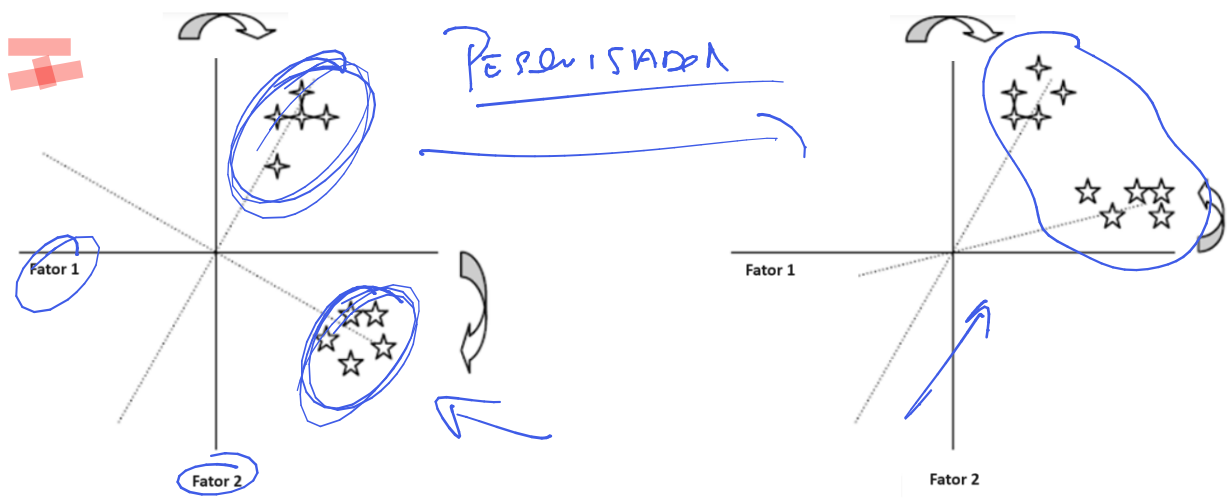

Figure 2: Representação gráfica da rotação ortogonal de fatores.

Nesse caso, a ideia consiste em considerar a matriz T ortogonal tal que $\mathbf{T}\mathbf{T}^\top = \mathbf{T}^\top\mathbf{T} = \mathbf{I}$ e rotacionar a matriz de cargas fatoriais fazendo

$$\hat{\mathbf{L}}^* = \hat{\mathbf{L}}\mathbf{T}$$

$y = \theta X$

note que $\hat{\mathbf{L}}^*\hat{\mathbf{L}}^\top = (\hat{\mathbf{L}}\mathbf{T})(\hat{\mathbf{L}}\mathbf{T})^\top = \hat{\mathbf{L}}\hat{\mathbf{L}}^\top$

Os critérios para rotação ortogonal de fatores mais comumente utilizadas são:

- Varimax (Kaiser 1958): Encontrar fatores com variabilidade máxima nas cargas fatoriais;
- Quartimax (Jobson, 1996): Encontrar fatores que levem ao máximo da variabilidade dos quadrados das cargas fatoriais sobre todos os fatores;

$y = \theta X$

- Orthomax (Jobson, 1996);

Os escores das componentes podem ser usados para a ordenação das observações e podem ser estimados para cada elemento amostral a partir de duas possíveis estratégias:

- Mínimos quadrados ponderados

$$\hat{F}_j = (\hat{\mathbf{L}}^\top \mathbf{\Psi} \hat{\mathbf{L}})^{-1} (\hat{\mathbf{L}}^\top \mathbf{\Psi}) \mathbf{z}_j,$$

TRANSP.

para $j = 1, ..., n$.

- Método de regressão

$$\hat{F}_j = \hat{\mathbf{L}}^\top \hat{\mathbf{P}}^{-1} \mathbf{z}_j,$$

para $j = 1, ..., n$.

7.2.5 Critérios para a escolha do número de fatores

- Análise da proporção da variância,
- Número de autovalores de R maiores do que 1,
- Gráfico scree-plot

λ_1	λ_2	λ_3
2,5	1,3	0,5