Estatística Multivariada

Notas de aula - Estatística para Ciência de Dados - Curso de Pós-Graduação - PUC Minas Gerais

Prof. Vinícius Osterne

Divisão do curso

- Apresentação do curso
- Conceitos básicos
- Análise exploratória
- Probabilidade (e suas distribuições)
- Análise inferencial
- Técnicas multivariadas I (aprendizado supervisionado)
- Técnicas multivariadas II (aprendizado não supervisionado)

Divisão do curso por datas

- **04/abril:** apresentação do curso e conceitos básicos
- **11/abril:** análise exploratória, probabilidade (e suas distribuições) e análise inferencial
- **18/abril:** técnicas multivariadas I (aprendizado supervisionado)
- **25/abril:** técnicas multivariadas II (aprendizado não supervisionado)
- **02/maio:** tópicos extras
- **09/maio:** apresentação dos trabalhos

1. Apresentação do curso

1.1. Definições

- Ramo da estatística que se dedica a estudar e desenvolver métodos para descrever e analisar dados com múltiplas variáveis
- Conjunto de técnicas que, simultaneamente, analisam múltiplas medidas sobre cada indivíduo ou objeto

1.2. Objetivos

- Investigar como as variáveis se influenciam mutuamente (entender conexões e padrões ocultos)
- Encontrar maneiras de representar dados multivariados em dimensões menores, mantendo a maior parte da informação original
- Utilizar técnicas multivariadas para prever resultados com base em várias variáveis
- Criar gráficos e representações visuais para explorar a estrutura dos dados multivariados

y X_1 X_2

CARGO RENDA IDADE TEMPO DE ESTUDO

1.3. Aplicações

- Modelos de regressão múltiplo
- Modelos de regressão multivariado
- Modelos de regressão para dados longitudinais / PAINEL.
- Planejamento de experimentos
- Classificação

1 ou mais

1.4. Conceitos prévios necessários (contexto univariado)

- Análise exploratória

- Probabilidade (e suas distribuições)
- Análise inferencial
- Álgebra Linear (contexto multivariado)

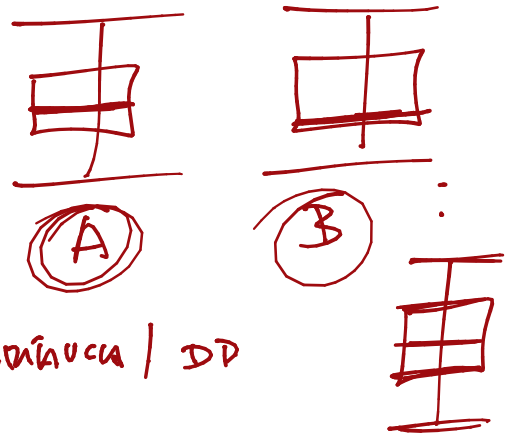

(1) AED:

IDADE: MÉDIA | MAX | MIN | FAIXA ETÁRIA | VARIÁVEL | DP

OUTLIER | VALOR EXTREMO

MEDIANA

(2) PROB

(3) INFERÊNCIA

(4) VETOR

MATRIZ

$X_1 \quad X_2 \ldots X_{10}$

$i=1$
$i=2$
$\vdots$
$i=n$

SUPONHA DA DISTRIBUIÇÃO

2. Conceitos básicos

2.1. Organização dos dados

- A organização dos dados multivariados é feito com o auxílio de vetores e matrizes
- Nessas matrizes, as colunas representam as variáveis (características medidas) e as linhas representam as unidade amostrais (itens observados)
- Assim, sejam $\mathbf{X}_1, \mathbf{X}_2, \ldots, \mathbf{X}_p$ variáveis aleatórias
- Denotamos por $\mathbf{X}$ a matriz que contém e organiza as variáveis $\mathbf{X}_1, \mathbf{X}_2, \ldots, \mathbf{X}_p$, ou seja, $\mathbf{X} = (\mathbf{X}_1, \mathbf{X}_2, \ldots, \mathbf{X}_p)^\top$
- Expadindo $\mathbf{X}$, obtemos

COLUNAS

$$\mathbf{X} = [\mathbf{X}_1 \quad \mathbf{X}_2 \quad \ldots \quad \mathbf{X}_p] = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix},$$

DATASET

n

onde x_{ij} representa o valor da variável j na observação i, n é o número de observações e p é o número de variáveis

- Então, por exemplo, podemos ter uma matriz $\mathbf{X}$ que representa duas matrizes: idade (X_1) e gênero (X_2), ou seja, teremos a seguinte representação

$$\mathbf{X} = [\mathbf{X}_1 \quad \mathbf{X}_2] = \begin{bmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \\ \vdots & \vdots \\ x_{n1} & x_{n2} \end{bmatrix} = \begin{bmatrix} 23 & F \\ 67 & M \\ \vdots & \vdots \\ 38 & F \end{bmatrix},$$

  onde F indica sexo feminino e M indica sexo masculino.

- Se estamos utilizando o R, a organização dos dados para um caso particular pode ser dado por

```
x1 = c(23, 67, 30, 40, 38)
x2 = c(1, 0, 0, 1, 1)
X = matrix(cbind(x1, x2), nrow = 5, ncol = 2)
X
```

CBIND

```
##      [,1] [,2]
## [1,]   23    1
## [2,]   67    0
## [3,]   30    0
## [4,]   40    1
## [5,]   38    1
```

3. Análise exploratória

- A partir de uma matriz de dados, podemos começar a realizar algumas análises descritivas
- Nesta subseção, apresentaremos as principais e algumas ferramentas gráficas comuns no contexto multivariado

- $\mathbb{E}(X) = \sum_i x \, \mathbb{P}(X = x)$
- $\mathbb{E}(X) = \int x f_X(x) \, dx$

3.1. Vetor de médias

- O vetor de médias da matriz de dados $\mathbf{X}$ é dado por

$$\boldsymbol{\mu} = [\, \mu_1 \quad \mu_2 \quad \ldots \quad \mu_p \,],$$

onde μ_j é a média da variável $\mathbf{X}_j$, que é dada por $\boxed{\mu = \mathbb{E}(\mathbf{X}_j)}$ com $j = 1, 2, \ldots, n$.

$F = \mathcal{N}$
$\mu = 0$

```
means = colMeans(X)
means
```

$\mu = (39{,}6 \; ; \; 0{,}6)$

```
## [1] 39.6  0.6
```

$\hat{\mu} = \bar{X} = \dfrac{\sum_{i=1}^{n} X_i}{n}$

3.2. Matriz de variâncias e covariâncias

- A matriz de variâncias e covariâncias da matriz de dados $\mathbf{X}$ é dada por

$$\boxed{\boldsymbol{\Sigma} = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_{pp} \end{bmatrix},}$$

$X_1 \quad X_2$

$\Sigma = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}$

2×2

$\times p$

onde σ_{jk} é a covariância entre as variáveis $\mathbf{X}_j$ e $\mathbf{X}_k$, que é dada por

$$\sigma_{jk} = \mathbb{E}[(\mathbf{X}_j - \mu_{\mathbf{X}_j})(\mathbf{X}_k - \mu_{\mathbf{X}_k})]$$

- Quando $j = k$, temos $\sigma_{jj} = \sigma_j^2$, que é a variância da variável $\mathbf{X}_j$, ou seja, a diagonal principal da matriz $\boldsymbol{\Sigma}$ é composta pelas variâncias das variáveis da matriz de dados $\mathbf{X}$. Assim, podemos reescrever essa matriz da seguinte forma

$\mathrm{Cov}(X_1, X_1) = \mathrm{Var}(X_1)$

$\mathbb{E}[(x - \mu)^2]$.

$$\boldsymbol{\Sigma} = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_{pp} \end{bmatrix} = \begin{bmatrix} \sigma_1^2 & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_2^2 & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_p^2 \end{bmatrix}.$$

- A matriz de covariância também pode ser diagnonal, ou seja

$$\boldsymbol{\Sigma} = \begin{bmatrix} \sigma_1^2 & 0 & \cdots & 0 \\ 0 & \sigma_2^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 \end{bmatrix},$$

X_1, X_2 IND $\Rightarrow Cov(X_1, X_2) = 0$

nesse caso, as variáveis $\mathbf{X}_j$ e $\mathbf{X}_k$, para $j \neq k$, são independentes e, por isso, a covariância é igual a zero (cuidado com essa afirmação, pois o contrário "se duas variáveis tem covariância igual a zero, então elas são independentes" não é sempre válida).

```
covs = cov(X)
covs
```

```
##         [,1]  [,2]
## [1,] 280.30 -4.45
## [2,]  -4.45  0.30
```

$$\frac{Cov(X_1, X_2)}{\sqrt{V(X_1)\ V(X_2)}}$$

3.3. Matriz de correlação

- A matriz de correlação da matriz de dados $\mathbf{X}$ é dada por

$$\mathbf{C} = \begin{bmatrix} \rho_{11} & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{21} & \rho_{22} & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \cdots & \rho_{pp} \end{bmatrix},$$

$\sqrt{V(X_1)}\ \sqrt{X_2}$

$\sqrt{V(X_1) \cdot V(X_2)}$

onde ρ_{jk} é a correlação entre as variáveis $\mathbf{X}_j$ e $\mathbf{X}_k$ que é dada por

$$\rho_{jk} = \frac{\sigma_{jk}}{\sigma_j \sigma_k},$$

sendo $\boxed{-1 \leq \rho_{jk} \leq 1}$

- Quando $j = k$, temos $\rho_{jj} = 1$, pois a correlação entre uma variável e ela mesma é igual a 1. Assim, podemos reescrever essa matriz da seguinte forma

$$\mathbf{C} = \begin{bmatrix} \rho_{11} & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{21} & \rho_{22} & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \cdots & \rho_{pp} \end{bmatrix} = \begin{bmatrix} 1 & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{21} & 1 & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \cdots & 1 \end{bmatrix}.$$

- A matriz de correlação também pode ser diagonal, ou seja

$$\mathbf{C} = \begin{bmatrix} \rho_1 & 0 & \cdots & 0 \\ 0 & \rho_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \rho_p \end{bmatrix},$$

UNIFORME

nesse caso, as variáveis $\mathbf{X}_j$ e $\mathbf{X}_k$, para $j \neq k$, são independentes e, por isso, a correlação é igual a zero (cuidado com essa afirmação, pois o contrário "se duas variáveis tem correlação igual a zero, então elas são independentes" não é sempre válida).

```
cors = cor(X)
cors
```

$-1 < \rho < 1$

```
##            [,1]       [,2]
## [1,]  1.0000000 -0.4852749
## [2,] -0.4852749  1.0000000
```

ρ

-1 $\quad -0{,}48 \quad 0 \quad 1$

$\rho < 0$ $\qquad \rho > 0$

3.4. Distâncias multivariadas

- Outras métricas utilizadas a partir da matriz de dados $\mathbf{X}$ são as chamadas distâncias multivariadas.
- Essas distâncias podem ser de **similaridade** (quanto maior o valor observado, mais parecidos são os objetos; o coeficiente de correlação, visto anteriormente, é um exemplo) ou de **dissimilaridade** (quanto maior o valor observado, menos parecidos serão os objetos; veremos alguns exemplos a seguir).
- As principais medidas de dissimilaridades são:

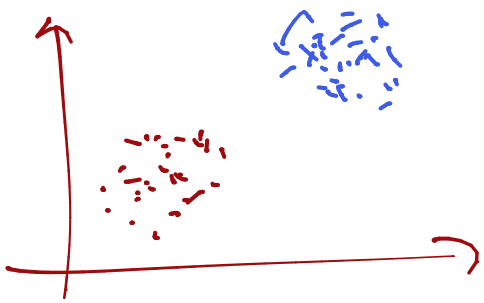

IGUAIS

DIFERENTES

(i.) Distância Euclidiana: medida mais comum de distância entre pontos em um espaço euclidiano, sendo definida por

$$d_e = \sqrt{\sum_{i=1}^{n}(x_i - y_i)^2},$$

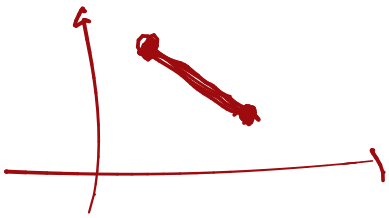

sendo X e Y duas variáveis aleatórias, com $i = 1, 2, \ldots n$. - No R, podemos calcular essa distância da seguinte forma:

```
x = c(2, 2, 6, 9, 3, 5, 6, 1)
y = c(16, 21, 12, 10, 10, 6, 8, 14)
d_e = sqrt(sum((x-y)^2))
d_e
```

```
## [1] 28.58321
```

QUADRADO

(ii.) Distância de Manhattan: também é uma medida comum de distância entre pontos, sendo definida por

$$d_{mh} = \sum_{i=1}^{n}|x_i - y_i|,$$

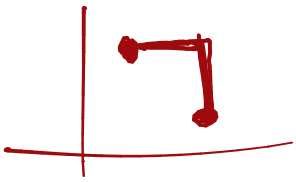

sendo X e Y duas variáveis aleatórias, com $i = 1, 2, \ldots n$. - No R, podemos calcular essa distância da seguinte forma:

```
x = c(2, 2, 6, 9, 3, 5, 6, 1)
y = c(16, 21, 12, 10, 10, 6, 8, 14)
d_mh = sqrt(sum(abs(x-y)))
d_mh
```

```
## [1] 7.937254
```

(iii.) Distância de Mahalanobis: é uma distância que leva em consideração a covariância entre variáveis e é uma extensão da distância euclidiana, sendo uma medida invariante à escala em que a variável foi medida, e é definida por

$$d_{mb}^2 = (\mathbf{X} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}_{\mathbf{X}}^{-1} (\mathbf{X} - \boldsymbol{\mu}),$$

sendo X a matriz de variáveis aleatórias e $\boldsymbol{\mu}$ e $\boldsymbol{\Sigma}_{\mathbf{X}}$ o vetor de médias e a matriz de covariância da matriz de dados, respectivamente. - No R, podemos calcular essa distância da seguinte forma:

$$\mathbf{X} = \begin{pmatrix} X_1 & X_2 & X_3 & X_4 \end{pmatrix} =$$

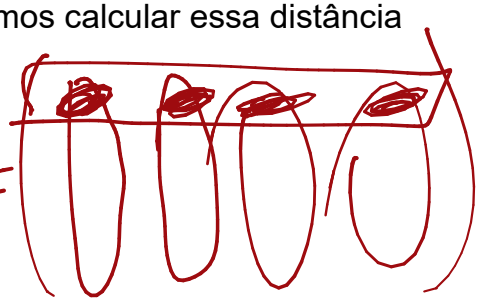

$\mu = (\mu_1 \ \mu_2 \ \mu_3 \ \mu_4)$

```
x1 = c(91, 93, 72, 87, 86, 73, 68, 87, 78, 99, 95, 76, 84, 96, 76, 80, 83, 8
4, 73, 74)
x2 = c(16, 6, 3, 1, 2, 3, 2, 5, 2, 5, 2, 3, 4, 3, 3, 3, 4, 3, 4, 4)
x3 = c(3, 4, 0, 3, 4, 0, 1, 2, 1, 2, 3, 3, 3, 2, 2, 2, 3, 3, 2, 2)
x4 = c(70, 88, 80, 83, 88, 84, 78, 94, 90, 93, 89, 82, 95, 94, 81, 93, 93, 9
0, 89, 89)
df_xy = data.frame(cbind(x1, x2, x3, x4))
mu_xy = colMeans(df_xy)
cov_xy = cov(df_xy)

d_mb = c()
for (i in 1:length(x1)) {
  d_mb[i] = (t(t(df_xy[i,] - mu_xy)) %*% solve(cov_xy) %*% t(df_xy[i,] - mu_
xy))
}
d_mb
```

$(x - \mu) \quad \Sigma_{xx} (x - \mu)$

```
##  [1] 16.5019630  2.6392864  4.8507973  5.2012612  3.8287341  4.0905633
##  [7]  4.2836303  2.4198736  1.6519576  5.6578253  3.9658770  2.9350178
## [13]  2.8102109  4.3682945  1.5610165  1.4595069  2.0245748  0.7502536
## [19]  2.7351292  2.2642268
```

```
d_mb_R = mahalanobis(df_xy, mu_xy, cov_xy)
d_mb_R
```

```
##  [1] 16.5019630  2.6392864  4.8507973  5.2012612  3.8287341  4.0905633
##  [7]  4.2836303  2.4198736  1.6519576  5.6578253  3.9658770  2.9350178
## [13]  2.8102109  4.3682945  1.5610165  1.4595069  2.0245748  0.7502536
## [19]  2.7351292  2.2642268
```

3.5. Análise gráfica

Gráfico de dispersão

- Utilizado para visualizar a relação entre duas variáveis quantitativas
- É possível detectar padrões e tendências nos dados e identificar possíveis correlações entre as variáveis
- No R, podemos usar os seguintes comandos:

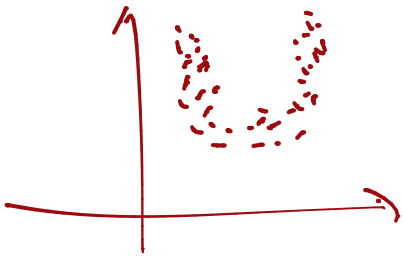

ALEATÓRIAS ~ N(0, 15)

```
x1 = 1:100
x2 = x1 + rnorm(100, mean = 0, sd = 15)
plot(x1, x2, pch = 19, col = "black", lwd = 1,
     xlab = "Idade (em ano)", ylab = "Tempo de espera (em anos)")
```

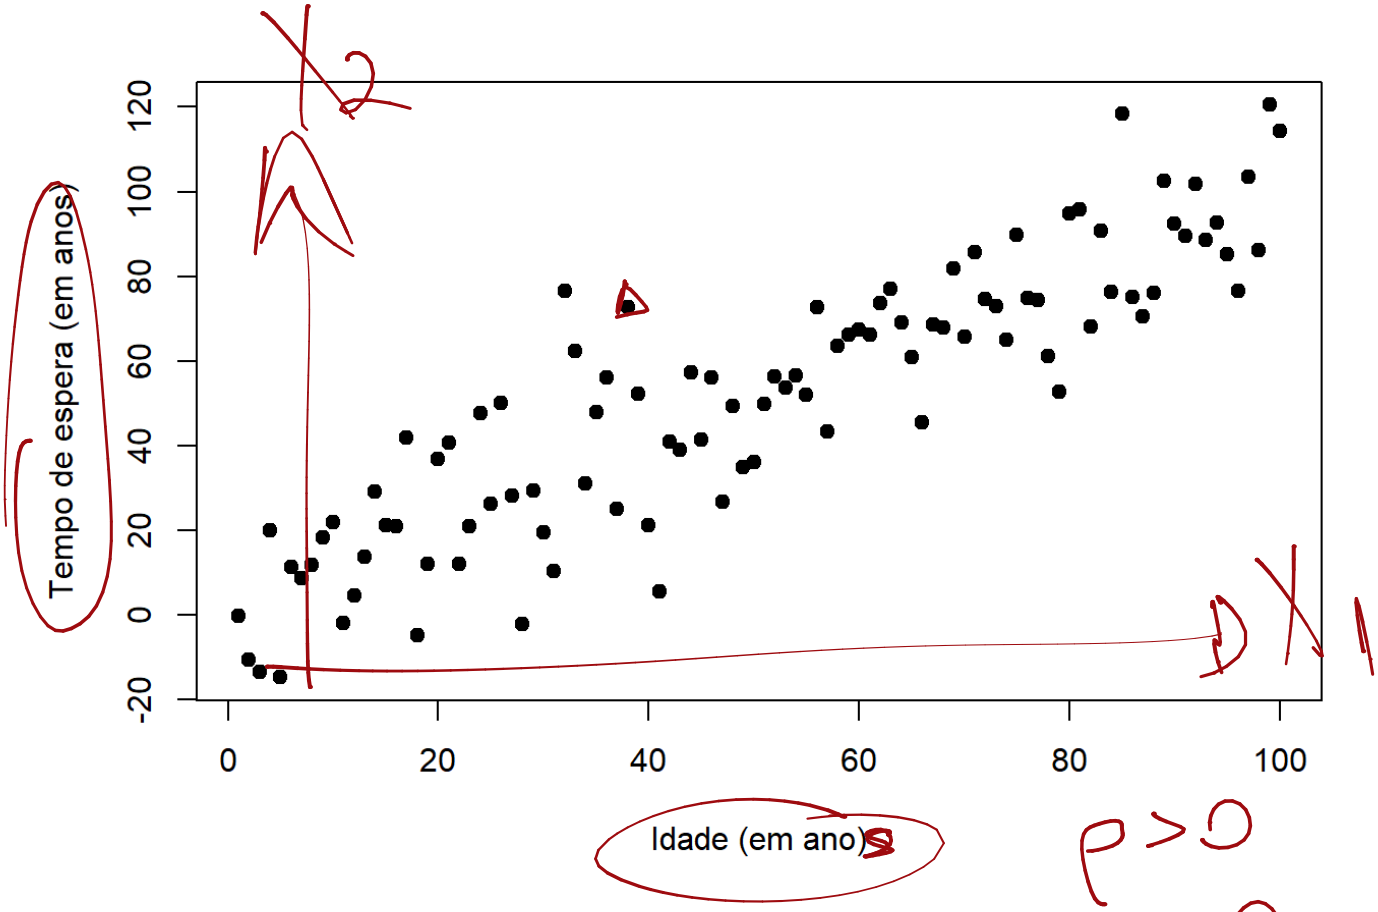

$\rho > 0$

$\rho < 0$

Histograma

- Utilizado para avaliar a forma da distribuição (assimetria e curtose)
- Embora seja univariado, vale usar como comparativo entre duas variáveis
- No R, podemos usar os seguintes comandos (o gráfico (A) refere-se à geração de números aleatórios de uma distribuição normal e o gráfico (B) refere-se à geração de números aleatórios de uma distribuição qui-quadrado):

```
x1 = rnorm(100, mean = 0, sd = 15)
x2 = rchisq(100, 5)
par(mfrow = c(1,2))
hist(x1, prob = T, main = "(A)")
hist(x2, prob = T, main = "(B)")
```

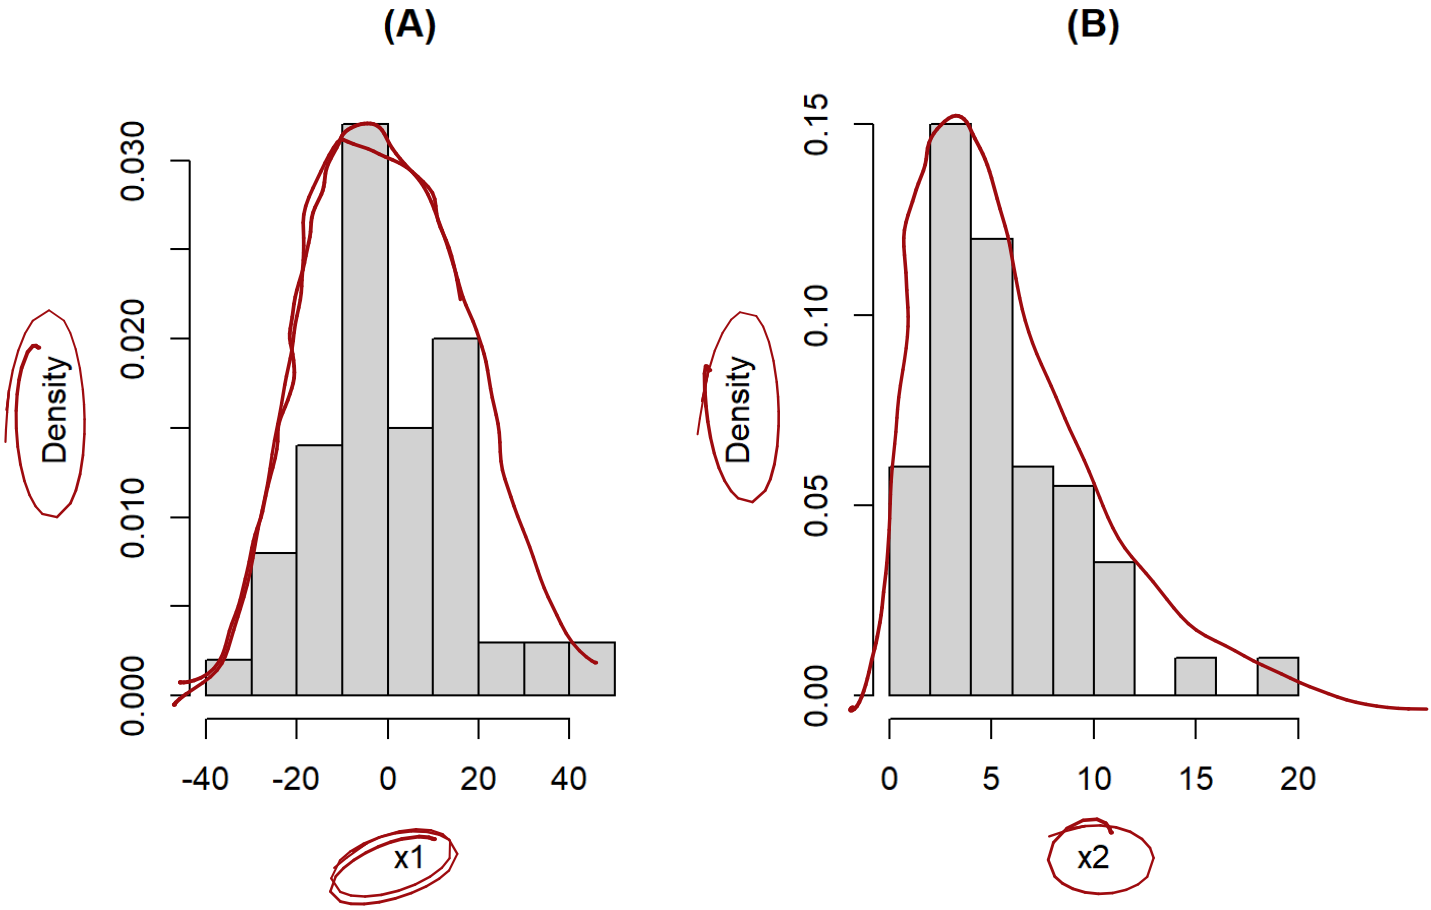

Gráfico de dispersão com múltiplas informações

- Utilizado para visualização múltipla: dispersão, histograma, cálculo de correlações e teste de hipóteses
- No R, podemos usar os seguintes comandos:

```
library(GGally)
```

```
## Warning: package 'GGally' was built under R version 4.2.3
```

```
## Carregando pacotes exigidos: ggplot2
```

```
## Warning: package 'ggplot2' was built under R version 4.2.3
```

```
## Registered S3 method overwritten by 'GGally':
##   method from
##   +.gg   ggplot2
```

```
library(ggplot2)
ggpairs(iris[,-5])+ theme_bw()
```

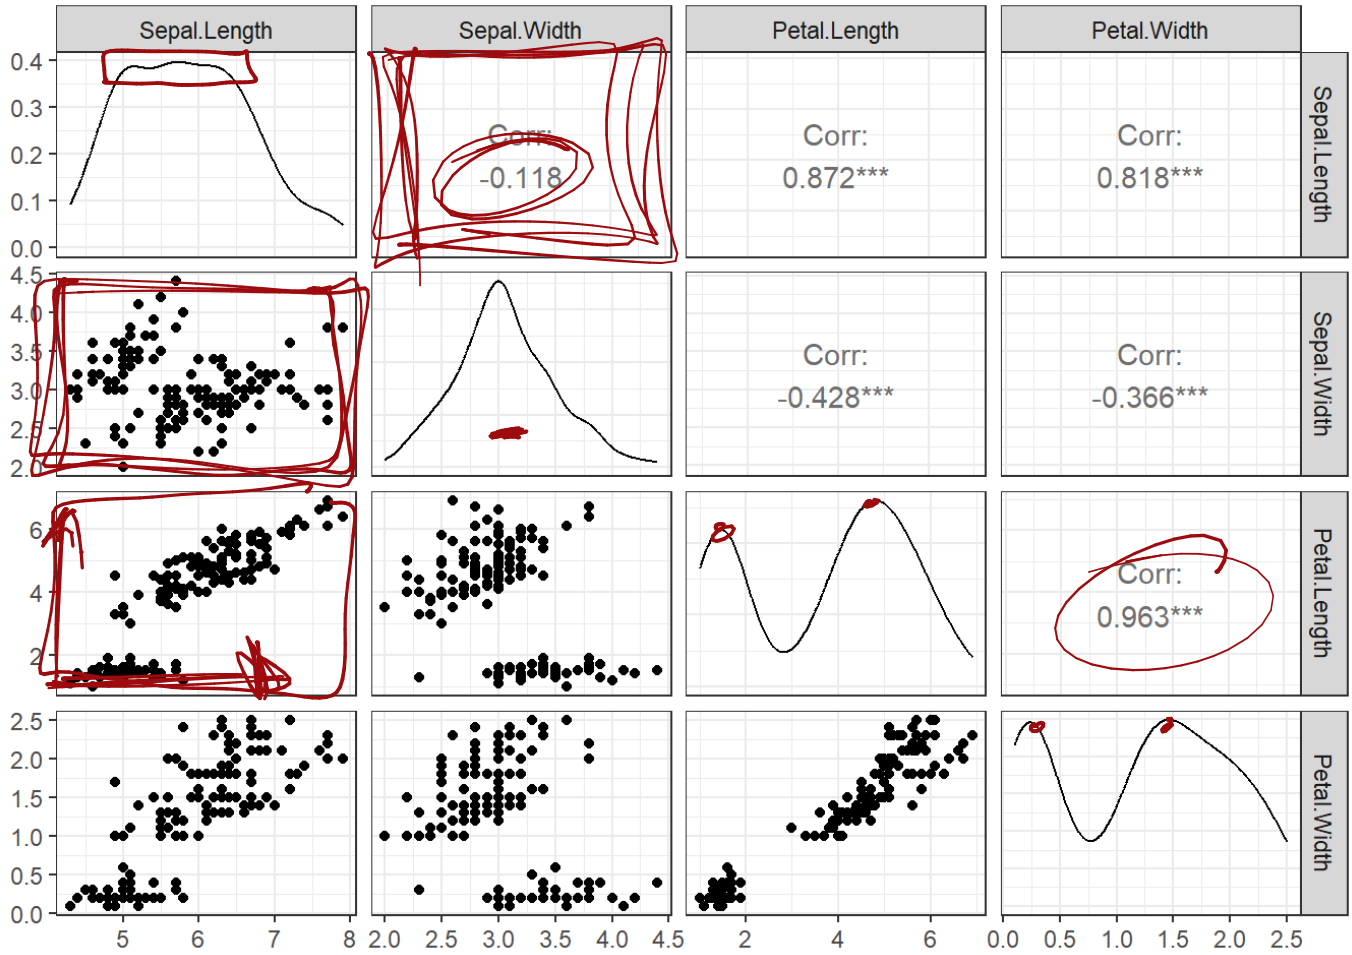

$X \sim Poi(\lambda)$ $X \sim Gama(\alpha, \beta)$

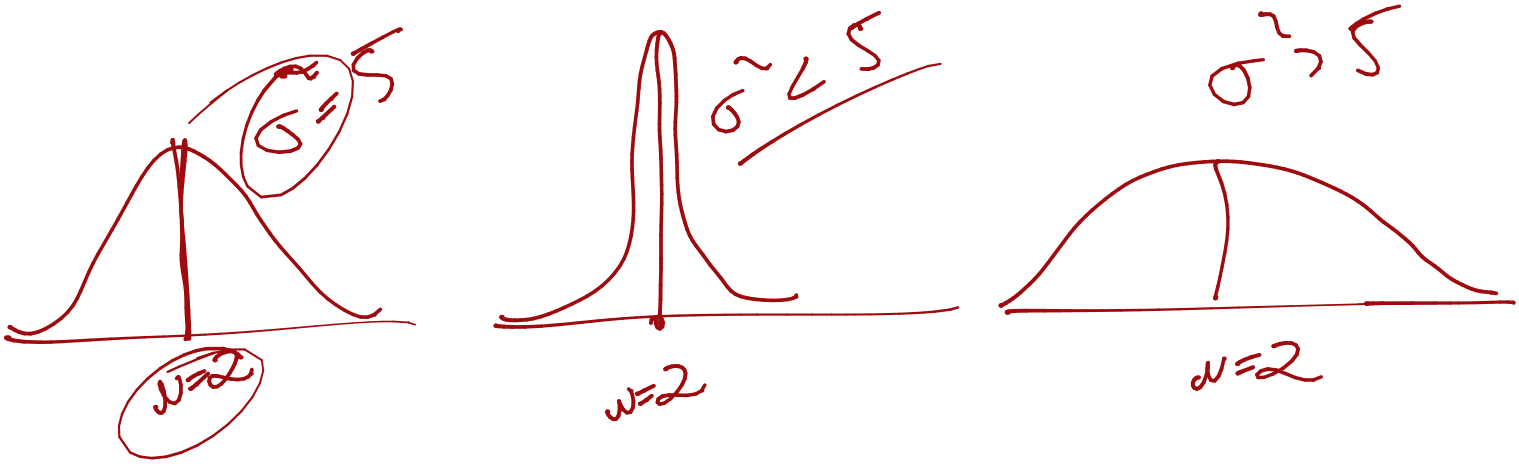

4. Probabilidade (e suas distribuições)

4.1. Distribuição Normal (ou Gaussiana)

- A distribuição normal é uma das distribuições de probabilidade mais utilizadas na Estatística

- É uma distribuição de probabilidade absolutamente contínua e, no **contexto univariado**, é parametrizada pela esperança matemática (número real μ) e pela variância (número real positivo σ^2).
- Assim, se $X \sim \mathcal{N}(\mu, \sigma^2)$, então sua função densidade de probabilidade é dada por

$$\boxed{f(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{1}{2\sigma^2}(x-\mu)^2\right\}}$$

UNI

- Importante ressaltar que se a distribuição normal tem média nula e variância unitária, então ela é chamada de distribuição normal centrada e reduzida ou de distribuição normal padrão.
- No **contexto multivariado**, essa distribuição é parametrizada pela esperança matemática (vetor real $\boldsymbol{\mu}$) e pela matriz de variâncias e covariâncias (matriz positiva definida $\boldsymbol{\Sigma}$).
- Assim, se $X \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, então sua função densidade de probabilidade é dada por

$N = (X_1\ X_2)$

$\Sigma_{2\times 2}$

$$f(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{k/2}|\boldsymbol{\Sigma}|^{1/2}} \exp\left(\boxed{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^T\boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu})}\right).$$

MULT

- Para gerar valores aleatórios dessa distribuição no R, usamos os seguintes comandos

$X_1\ X_2\ _{1\times 2}$ $\quad \Sigma \quad$ $X_1\ X_2$

$w = (\quad)_{2\times 1}$ $\quad 2\times 2 \quad$ $(\quad)_{2\times 1}$

```
library(faux)
```

```
## Warning: package 'faux' was built under R version 4.2.3
```

$1\times 2 \quad 2\times 2 \quad 2\times 1$

1

```
##
## ************
## Welcome to faux. For support and examples visit:
## https://debruine.github.io/faux/
## - Get and set global package options with: faux_options()
## ************
```

```
X = rnorm_multi(100, 3, c(0, .5, 1),
                r = c(0.2, -0.5, 0.5),
                varnames=c("X1", "X2", "X3"))
cor(X)
```

$X_1 \quad X_2 \quad X_3$

$y \rightarrow X$

```
##            X1        X2         X3
## X1  1.0000000 0.2700962 -0.4398205
## X2  0.2700962 1.0000000  0.4657821
## X3 -0.4398205 0.4657821  1.0000000
```

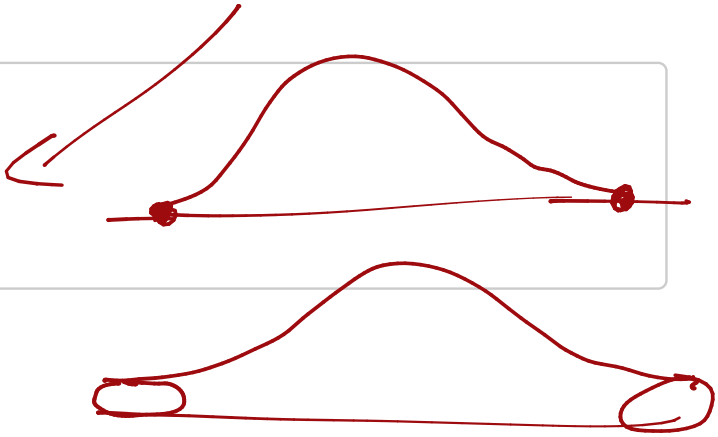

4.2. Distribuição Student-t

- A distribuição Student-t (ou somente distribuição t) também é uma das distribuições de probabilidade mais utilizadas na Estatística
- É uma distribuição de probabilidade absolutamente contínua e, no **contexto univariado**, é parametrizada pela esperança matemática (número real μ), pela variância (número real positivo σ^2) e pelos graus de liberdade (número inteiro positivo ν)
- Assim, se $X \sim \mathcal{T}(\mu, \sigma^2, \nu)$, então sua função densidade de probabilidade é dada por

$\theta = (\mu, \sigma^2)$

$$\boxed{f(x|\mu, \sigma^2, \nu) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\Gamma\left(\frac{\nu}{2}\right)\left(1 + x^2/\nu\right)^{(\nu+1)/2}}}$$

MAMA VARIOBIS

μ, σ^2

- Essa distribuição é útil quando trabalhamos com amostras pequenas, é mais robusta em relação a outliers e variações extremas nos dados, à medida que o tamanho da amostra aumenta, essa distribuição se aproxima da distribuição normal (ou seja, para amostras grandes, podemos usar a distribuição normal como uma aproximação da distribuição t.
- No **contexto multivariado**, essa distribuição é parametrizada pela esperança matemática (vetor real $\boldsymbol{\mu}$), pela matriz de variâncias e covariâncias (matriz positiva definida $\boldsymbol{\Sigma}$) e pelos graus de liberdade (número inteiro positivo ν).
- Assim, se $X \sim \mathcal{T}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, então sua função densidade de probabilidade é dada por

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{n/2}|\boldsymbol{\Sigma}|^{1/2}}\left(1 + \frac{(\mathbf{x} - \mu)^T\boldsymbol{\Sigma}^{-1}(\mathbf{x} - \mu)}{\nu}\right)^{-\frac{\nu+n}{2}},$$

onde $\mathbf{X}$ é a matriz de dados observada, $\boldsymbol{\mu}$ é o vetor de médias, $\boldsymbol{\Sigma}$ é a matriz de covariância, k é o número de variáveis e ν é o número de graus de liberdade (que determina a forma da distribuição).
- Para gerar valores aleatórios dessa distribuição no R, usamos os seguintes comandos

```r
library(LaplacesDemon)
x <- seq(-2,4,length=21)
y <- 2*x+10
z <- x+cos(y)
mu <- c(1,12,2)
S <- matrix(c(1,2,0,
              2,5,0.5,
              0,0.5,3), 3, 3)
df <- 4
X <- rmvt(1000, c(0,1,2), S, 5)
head(X)
```

```
##            [,1]       [,2]      [,3]
## [1,] -2.0141139 -2.4665171  3.367597
## [2,] -0.8998318 -0.1056510  3.348149
## [3,] -1.1692364 -0.2009242  2.804507
## [4,] -0.3231125  1.3251987  2.394196
## [5,] -0.7410704 -2.0631195 -2.951469
## [6,]  0.5750129  3.3039122  5.673878
```

```r
cor(X)
```

```
##             [,1]       [,2]        [,3]
## [1,]  1.00000000 0.89504754 -0.01871065
## [2,]  0.89504754 1.00000000  0.09739252
## [3,] -0.01871065 0.09739252  1.00000000
```

Referências

- https://des.ufla.br/~danielff/meusarquivospdf/prefacioem.pdf (https://des.ufla.br/~danielff/meusarquivospdf/prefacioem.pdf)
- https://docs.ufpr.br/~soniaisoldi/ce076/9ANALISEAGRUPAMENTOS.pdf (https://docs.ufpr.br/~soniaisoldi/ce076/9ANALISEAGRUPAMENTOS.pdf)