Universidade Federal do Ceará
Disciplina de Modelos de Regressão
Ministrado pelo prof. Dr. Juvêncio Santos Nobre

Seleção de variáveis

Vinícius Silva Osterne Ribeiro
Estatístico e Cientista de Dados
vinicius@osterne.com | www.osterne.com

Divisão da aula

- **Conceitos prévios;**
- **Métodos de seleção:**
  - Inclusão passo a frente (*Forward*);
  - Eliminação passo atrás (*Backward*);
  - Seleção passo a passo (*Stepwise*);
- **Prática com o software R**;

Conceitos prévios

Conceitos prévios

- Na **análise de diagnóstico** de um modelo de regressão vemos algumas técnicas para verificar se um modelo se adequa bem aos dados ou não;

- Dentre essas técnicas, destacam-se a análise de resíduos, a análise de pontos de alavanca e a análise de pontos influentes, por exemplo;

Conceitos prévios

- Além dessa linha de análise de diagnóstico, precisamos ter conhecimento (e domínio) sobre os chamados **métodos de seleção de variáveis**;

- Diferentemente da primeira análise citada, as técnicas de seleção consistem em avaliar qual modelo é o melhor para o conjunto de dados em análise, dado um conjunto de outros modelos;

- Em outras palavras, o que estamos fazendo é selecionando variáveis obedecendo a determinada abordagem, que apresentaremos em detalhes neste aula;

Conceitos prévios

- Mas ao se fazer esse tipo de análise, a pergunta principal para que tenhamos uma motivação para estudar esse ponto é: **por que selecionar variáveis/modelos?**

Conceitos prévios

- Elencamos alguns dos principais motivos abaixo:

Conceitos prévios

- Elencamos alguns dos principais motivos abaixo:
  - **Parcimônia:** precisamos de um modelo capaz de proporcionar um bom ajuste com a menor quantidade possível de parâmetros;

Conceitos prévios

- Elencamos alguns dos principais motivos abaixo:
  - **Parcimônia:** precisamos de um modelo capaz de proporcionar um bom ajuste com a menor quantidade possível de parâmetros;
  - **Interpretabilidade:** preciamos explicar a relação entre as variáveis da maneira mais simples possível;

Conceitos prévios

- Elencamos alguns dos principais motivos abaixo:
  - **Parcimônia:** precisamos de um modelo capaz de proporcionar um bom ajuste com a menor quantidade possível de parâmetros;
  - **Interpretabilidade:** preciamos explicar a relação entre as variáveis da maneira mais simples possível;
  - **Inferências:** muitos pararâmetros no modelo significa menos graus de liberdade para os resíduos e, consequentemente, menor precisão para as inferências a serem realizadas, tais como intervalos de confiança e teste de hipóteses;

Conceitos prévios

- Elencamos alguns dos principais motivos abaixo:
  - **Parcimônia:** precisamos de um modelo capaz de proporcionar um bom ajuste com a menor quantidade possível de parâmetros;
  - **Interpretabilidade:** preciamos explicar a relação entre as variáveis da maneira mais simples possível;
  - **Inferências:** muitos pararâmetros no modelo significa menos graus de liberdade para os resíduos e, consequentemente, menor precisão para as inferências a serem realizadas, tais como intervalos de confiança e teste de hipóteses;
  - **Generalização:** quanto mais complexo o modelo for, menor será seu poder de generalização, embora apresente melhor ajuste para os dados;

Conceitos prévios

- Vale ressaltar que antes de se utilizar qualquer método de seleção de modelos, é importante que o pesquisador avalie, juntamente com um especialista da área, se as variáveis:
  - Realmente pertencem ao contexto do problema;
  - Apresentam informações redundantes;
  - Apresentam elevado erro de medida;

Conceitos prévios

- Dentre as técnicas de seleção de modelos existentes na literatura, vamos abordar as seguintes nesta aula:
  - Inclusão passo a frente (*Forward*);
  - Eliminação passo atrás (*Backward*);
  - Seleção passo a passo (*Stepwise*);

Conceitos prévios

- Mas existem muitas outras técnicas, tais como:
  - Lasso;
  - Teste da razão de verossimilhanças;
  - AIC;
  - BIC;

Conceitos prévios

Algumas observações:

- **Observação 1:** em todos os casos que estudaremos nos tópicos seguintes, vamos considerar que o modelo em estudo é linear múltiplo da forma:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + ... + \beta_{ip} + \epsilon_i, \qquad i = 1, 2, ..., n,$$

sendo $\boldsymbol{\beta} = (\beta_0, \beta_1, ..., \beta_p)^\top$ os parâmetros a serem estimados, $\mathbf{X} = (X_1, X_2, ..., X_p)$ a matriz de delineamento (ou de covariáveis) e ϵ_i é o erro (variação de Y_i não explicada pelo modelo), tal que $\epsilon_i \sim \mathcal{N}(0, \sigma^2)$.

Conceitos prévios

- **Observação 2:** procedimentos automáticos não devem substituir o bom senso e o conhecimento sobre o problema;

- **Observação 3:** escolhendo o modelo final, ainda é preciso verificar a significância das covariáveis e verificar adequação do modelo, realizando as técnicas de diagnóstico;

Métodos de seleção

Métodos de seleção

- **Métodos de seleção:**

  Inclusão passo a frente (*Forward*);

  Eliminação passo atrás (*Backward*);

  Seleção passo a passo (*Stepwise*);

Métodos de seleção

- **Métodos de seleção:**
  - Inclusão passo a frente (*Forward*);
  - Eliminação passo atrás (*Backward*);
  - Seleção passo a passo (*Stepwise*);

Métodos de seleção

- Esse método consiste em iniciar a seleção com o modelo mais simples possível, ou seja, o primeiro passo é considerar um modelo somente com o intercepto, que é dado por:

$$Y_i = \beta_0 + \epsilon_i, \qquad i = 1, 2, ..., n,$$

Métodos de seleção

- O segundo passo é adicionar uma covariável X_j a esse modelo, com $j = 1, 2, ..., p$, e realizar p testes, tais que:

$$H_0 : \beta_j = 0$$
$$H_1 : \beta_j \neq 0,$$

e avaliar os níveis descritivos de cada uma desses testes;

- O teste a ser considerado nesse caso pode ser o teste F ou o teste T, por exemplo;

Métodos de seleção

- Com esses p níveis descritivos obtidos para os p testes, observamos aquele com o menor nível descritivo e o chamamos de p_j;

- Se p_j nos informa que o teste é significativo, ou seja, que rejeitamos H_0, então a variável X_j entra no modelo;

Métodos de seleção

- Supondo que essa covariável é a X_3, então o novo modelo será dado por:

$$Y_i = \beta_0 + \beta_3 X_{i3} + \epsilon_i, \qquad i = 1, 2, ..., n.$$

Métodos de seleção

- Para a inclusão de uma nova variável, repetimos o procedimento, ou seja, realizamos agora $(p-1)$ testes, pois já temos uma variável incluída no modelo, e avaliamos aquele com o menor nível descritivo;

- Se esse valor for menor que o nível de significância, a variável entra no modelo. Caso contrário, o procedimento é finalizado e declaramos o modelo atual como o escolhido;

Métodos de seleção

- **Observação:** se uma variável entra no modelo, ela não pode mais sair, mesmo que a sua contribuição deixe de ser significante quando uma outra variável entrar;

Métodos de seleção

- **Métodos de seleção:**
  - Inclusão passo a frente (*Forward*);
  - Eliminação passo atrás (*Backward*);
  - Seleção passo a passo (*Stepwise*);

Métodos de seleção

- O procedimento agora será invertido, se comparmos com o procedimento do método de inclusão passo a frente (*Forward*);

Métodos de seleção

- Agora, o primeiro passo é considerar o modelo com todas as p variáveis, que será dado por:

$$Y_i = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + ... + \beta_p X_p + \epsilon_i, \qquad i = 1, 2, ..., n.$$

Métodos de seleção

- O segundo passo consiste remover, uma a uma, as covariáveis do modelo completo e calcular os níveis descritivos correspondentes aos respectivos testes, ou seja, vamos considerar $(p-1)$ testes, tais que:

$$H_0 : \beta_j = 0$$
$$H_1 : \beta_j \neq 0$$

Métodos de seleção

- Com esses $(p-1)$ níveis descritivos obtidos para os $(p-1)$ testes, observamos aquele com o maior nível descritivo e o chamamos de p_j;

- Se p_j nos informa que o teste nao é significativo, ou seja, que não rejeitamos H_0, então a variável X_j sai do modelo;

Métodos de seleção

- Supondo que essa covariável é a X_3, então o novo modelo será dado por:

$$Y_i = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_4 X_4 + ... + \beta_p X_p + \epsilon_i, \qquad i = 1, 2, ..., n,$$

tal que $\beta_3 = 0$.

Métodos de seleção

- Para a exclusão de uma nova variável, repetimos o procedimento, ou seja, relizamos agora $(p-2)$ testes, pois já temos uma variável excluída do modelo, e avaliamos aquele com o maior nível descritivo;

- Se esse valor for maior que o nível de significância, a variável sai do modelo. Caso contrário, o procedimento é finalizado e declaramos o modelo atual como o selecionado;

Métodos de seleção

- **Observação:** se uma variável sai do modelo, ela não pode mais entrar;

Métodos de seleção

- **Métodos de seleção:**
  - Inclusão passo a frente (*Forward*);
  - Eliminação passo atrás (*Backward*);
  - Seleção passo a passo (*Stepwise*);

Métodos de seleção

- Esse método é uma mistura dos métodos de inclusão passo a frente (*Forward*) e eliminação passo atrás (*Backward*);

Métodos de seleção

- Ele inicia da mesma forma que dada pelo método *backward*, ou seja, o primeiro passo é considerar o modelo com todas as p variáveis, que será dado por:

$$Y_i = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + ... + \beta_p X_p + \epsilon_i, \qquad i = 1, 2, ..., n.$$

Métodos de seleção

- Entretanto, a cada passo do algoritmo será observado os níveis descritivos correspondentes à exclusão das variáveis que estão no modelo e também os níveis descritivos referentes à inclusão das variáveis que estão no modelo;

Métodos de seleção

- Dessa forma, supondo que queremos avaliar a variável X_3, então coletamos:
  - O nível do descritivo relacionado à sua exclusão;
  - O nível do descritivo relacionado à sua inclusão;

Métodos de seleção

- Para isso, definimos dois níveis de significância, dados por:
  - α_{entrada} : nível de significância aplicado à decisão de inserir a covariável;
  - $\alpha_{\text{saída}}$: nível de significância aplicado à decisão de excluir a covariável;

Métodos de seleção

- Assim, enquanto houver alguma variável com $p < \alpha_{\text{entrada}}$ fora do modelo e/ou $p > \alpha_{\text{saída}}$ no modelo, o processo continua;

- Caso contrário, o procedimento é finalizado e declaramos o modelo atual como o selecionado;

Prática com o software R.

fim!

Obrigado pela atenção ☺

E-mail

vinicius@osterne.com

Website

www.osterne.com