ESTATÍSTICA MULTIVARIADA

Notas de aula - PUC Minas

Prof. Vinícius Osterne

www.osterne.com – vinicius@osterne.com

Conteúdo

1 Introdução **4**
1.1 Definições . . . 4
1.2 Objetivos . . . 4
1.3 Aplicações . . . 4
1.4 Conceitos prévios necessários (contexto univariado) . . . 4

2 Conceitos básicos **5**
2.1 Organização dos dados . . . 5

3 Análise exploratória **6**
3.1 Vetor de médias . . . 6
3.2 Matriz de variâncias e covariâncias . . . 6
3.3 Matriz de correlação . . . 7
3.4 Distâncias multivariadas . . . 7
3.5 Análise gráfica . . . 9
3.5.1 Gráfico de dispersão . . . 9
3.5.2 Histograma . . . 9
3.5.3 Gráfico de dispersão com múltiplas informações . . . 9

4 Probabilidade (e suas distribuições) **10**
4.1 Distribuição Normal (ou Gaussiana) . . . 10
4.2 Distribuição Student-t . . . 10

5 Inferência **12**
5.1 Conceitos prévios . . . 12
5.2 Sobre o vetor de médias de uma população . . . 12
5.3 Sobre o vetor de médias de duas populações independentes . . . 13
5.4 Sobre o vetor de médias de populações paredas (medidas repetidas) . . . 14
5.5 Sobre o vetor de médias de mais de uma população (MANOVA) . . . 14

6 Técnicas multivariadas I (redução de dimensionalidade) **16**
6.1 Análise de componentes principais . . . 16
6.1.1 Conceitos iniciais . . . 16
6.1.2 Contexto estatístico . . . 16
6.1.3 ACP via matriz de covariância . . . 17
6.1.4 ACP via matriz de correlação . . . 18
6.1.5 Determinação do número de componentes principais . . . 19
6.2 Análise Fatorial . . . 20
6.2.1 Conceitos iniciais . . . 20
6.2.2 Estrutura . . . 20
6.2.3 Estimação do modelo usando o método da máxima verossimilhança . . . 21
6.2.4 Rotação ortogonal de fatores . . . 22
6.2.5 Critérios para a escolha do número de fatores . . . 23
6.3 Análise de correlação canônica . . . 23
6.3.1 Conceitos iniciais . . . 23
6.3.2 Estrutura . . . 23

7 Técnicas multivariadas II (aprendizado supervisionado) 25
7.1 Modelo de regressão linear multivariado . . . 25
7.1.1 Estrutura . . . 25
7.1.2 Estimação dos parâmetros . . . 25
7.1.3 Predições . . . 26
7.1.4 Aplicação em dados reais . . . 26
7.2 Análise de discriminante . . . 31
7.2.1 Análise Discriminante Linear (LDA) . . . 32
7.2.2 Análise Discriminante Quadrática (QDA) . . . 32
7.2.3 Naive Bayes . . . 33
7.3 Classificador linear de mínimos quadrados . . . 33

8 Técnicas multivariadas III (aprendizado não supervisionado) 35
8.1 Análise de agrupamento (ou de cluster) . . . 35
8.1.1 Agrupamento Hierárquico . . . 35
8.1.2 K-Means . . . 36
8.1.3 Mistura de Gaussianas . . . 36
8.1.4 Coeficientes de concordância . . . 37
8.1.5 Métodos de escolha do número de grupos . . . 37

9 Técnicas multivariadas IV (tópicos extras) 38
9.1 Equações Estruturais . . . 38
9.1.1 Conceitos iniciais . . . 38
9.1.2 Símbolos e terminologias . . . 38
9.1.3 Estrutura . . . 38
9.1.4 Aplicação . . . 39

1 Introdução

1.1 Definições

A estatística multivariada é um ramo da estatística que lida com a análise simultânea de duas ou mais variáveis. Ao contrário da estatística univariada, que se concentra em uma única variável, a estatística multivariada examina as relações entre múltiplas variáveis. Os métodos da estatística multivariada são utilizados em diversas áreas, como ciências sociais, biologia, economia, engenharia, entre outras.

1.2 Objetivos

Investigar como as variáveis se influenciam mutuamente (entender conexões e padrões ocultos). Encontrar maneiras de representar dados multivariados em dimensões menores, mantendo a maior parte da informação original. Utilizar técnicas multivariadas para prever resultados com base em várias variáveis. Criar gráficos e representações visuais para explorar a estrutura dos dados multivariados.

1.3 Aplicações

- Modelos de regressão múltiplo
- Modelos de regressão multivariado
- Modelos de regressão para dados longitudinais
- Planejamento de experimentos
- Classificação

1.4 Conceitos prévios necessários (contexto univariado)

- Análise exploratória;
- Probabilidade (e suas distribuições);
- Análise inferencial;
- Álgebra Linear (contexto multivariado).

2 Conceitos básicos

2.1 Organização dos dados

A organização dos dados multivariados é feito com o auxílio de vetores e matrizes. Nessas matrizes, as colunas representam as variáveis (características medidas) e as linhas representam as unidade amostrais (itens observados). Assim, sejam $\mathbf{X}_1$, $\mathbf{X}_2$, ..., $\mathbf{X}_p$ variáveis aleatórias

Denotamos por $\mathbf{X}$ a matriz que contém e organiza as variáveis $\mathbf{X}_1$, $\mathbf{X}_2$, ..., $\mathbf{X}_p$, ou seja, $\mathbf{X} = (\mathbf{X}_1, \mathbf{X}_2, ..., \mathbf{X}_p)^\top$. Expadindo $\mathbf{X}$, obtemos

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 & \mathbf{X}_2 & ... & \mathbf{X}_p \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix},$$

onde x_{ij} representa o valor da variável j na observação i, n é o número de observações e p é o número de variáveis

Então, por exemplo, podemos ter uma matriz $\mathbf{X}$ que representa duas matrizes: idade (X_1) e gênero (X_2), ou seja, teremos a seguinte representação

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 & \mathbf{X}_2 \end{bmatrix}^\top = \begin{bmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \\ \vdots & \vdots \\ x_{n1} & x_{n2} \end{bmatrix} = \begin{bmatrix} 23 & F \\ 67 & M \\ \vdots & \vdots \\ 38 & F \end{bmatrix},$$

onde F indica sexo feminino e M indica sexo masculino.

Se estamos utilizando o R, a organização dos dados para um caso particular pode ser dado por

```
x1 = c(23, 67, 30, 40, 38)
x2 = c(1, 0, 0, 1, 1)
X = matrix(cbind(x1, x2), nrow = 5, ncol = 2)
```

3 Análise exploratória

- A partir de uma matriz de dados, podemos começar a realizar algumas análises descritivas - Nesta subseção, apresentaremos as principais e algumas ferramentas gráficas comuns no contexto multivariado

3.1 Vetor de médias

O vetor de médias da matriz de dados $\mathbf{X}$ é dado por

$$\boldsymbol{\mu} = \begin{bmatrix} \mu_1 & \mu_2 & ... & \mu_p \end{bmatrix},$$

onde μ_j é a média da variável $\mathbf{X}_j$, que é dada por $\mu = \mathbb{E}(\mathbf{X}_j)$ com $j = 1, 2, ..., n$.

```
means = colMeans(X)
means
```

3.2 Matriz de variâncias e covariâncias

A matriz de variâncias e covariâncias da matriz de dados $\mathbf{X}$ é dada por

$$\boldsymbol{\Sigma} = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_{pp} \end{bmatrix},$$

onde σ_{jk} é a covariância entre as variáveis $\mathbf{X}_j$ e $\mathbf{X}_k$, que é dada por

$$\sigma_{jk} = \mathbb{E}[(\mathbf{X}_j - \mu_{\mathbf{X}_j})(\mathbf{X}_k - \mu_{\mathbf{X}_k})]$$

Quando $j = k$, temos $\sigma_{jj} = \sigma_j^2$, que é a variância da variável $\mathbf{X}_j$, ou seja, a diagonal principal da matriz $\boldsymbol{\Sigma}$ é composta pelas variâncias das variáveis da matriz de dados $\mathbf{X}$. Assim, podemos reescrever essa matriz da seguinte forma

$$\boldsymbol{\Sigma} = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_{pp} \end{bmatrix} = \begin{bmatrix} \sigma_1^2 & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_2^2 & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_p^2 \end{bmatrix}.$$

A matriz de covariância também pode ser diagnonal, ou seja

$$\boldsymbol{\Sigma} = \begin{bmatrix} \sigma_1^2 & 0 & \cdots & 0 \\ 0 & \sigma_2^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 \end{bmatrix},$$

nesse caso, as variáveis $\mathbf{X}_j$ e $\mathbf{X}_k$, para $j \neq k$, são independentes e, por isso, a covariância é igual a zero (cuidado com essa afirmação, pois o contrário "se duas variáveis tem covariância igual a zero, então elas são independentes"não é sempre válida).

```
covs = cov(X)
covs
```

3.3 Matriz de correlação

A matriz de correlação da matriz de dados $\mathbf{X}$ é dada por

$$\mathbf{C} = \begin{bmatrix} \rho_{11} & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{21} & \rho_{22} & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \cdots & \rho_{pp} \end{bmatrix},$$

onde ρ_{jk} é a correlação entre as variáveis $\mathbf{X}_j$ e $\mathbf{X}_k$ que é dada por

$$\rho_{jk} = \frac{\sigma_{jk}}{\sigma_j \sigma_k},$$

sendo $-1 \leq \rho_{jk} \leq 1$

Quando $j = k$, temos $\rho_{jj} = 1$, pois a correlação entre uma variável e ela mesma é igual a 1. Assim, podemos reescrever essa matriz da seguinte forma

$$\mathbf{C} = \begin{bmatrix} \rho_{11} & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{21} & \rho_{22} & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \cdots & \rho_{pp} \end{bmatrix} = \begin{bmatrix} 1 & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{21} & 1 & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \cdots & 1 \end{bmatrix}.$$

- A matriz de correlação também pode ser diagonal, ou seja

$$\mathbf{C} = \begin{bmatrix} \rho_1 & 0 & \cdots & 0 \\ 0 & \rho_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \rho_p \end{bmatrix},$$

nesse caso, as variáveis $\mathbf{X}_j$ e $\mathbf{X}_k$, para $j \neq k$, são independentes e, por isso, a correlação é igual a zero (cuidado com essa afirmação, pois o contrário "se duas variáveis tem correlação igual a zero, então elas são independentes"não é sempre válida).

```
cors = cor(X)
cors
```

3.4 Distâncias multivariadas

Outras métricas utilizadas a partir da matriz de dados $\mathbf{X}$ são as chamadas distâncias multivariadas. Essas distâncias podem ser de **similaridade** (quanto maior o valor observado, mais parecidos são os objetos; o coeficiente de correlação, visto anteriormente, é um exemplo) ou de **dissimilaridade** (quanto maior o valor observado, menos parecidos serão os objetos; veremos alguns exemplos a seguir). As principais medidas de dissimilaridades são:

- **Distância Euclidiana:** medida mais comum de distância entre pontos em um espaço euclidiano, sendo definida por

  $$d_e = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2},$$

  sendo X e Y duas variáveis aleatórias, com $i = 1, 2, ...n$. No R, podemos calcular essa distância da seguinte forma:

```
x = c(2, 2, 6, 9, 3, 5, 6, 1)
y = c(16, 21, 12, 10, 10, 6, 8, 14)
d_e = sqrt(sum((x-y)^2))
d_e
```

- **Distância de Manhattan:** também é uma medida comum de distância entre pontos, sendo definida por

$$d_{mh} = \sum_{i=1}^{n} |x_i - y_i|,$$

sendo X e Y duas variáveis aleatórias, com $i = 1, 2, ...n$. No R, podemos calcular essa distância da seguinte forma:

```
x = c(2, 2, 6, 9, 3, 5, 6, 1)
y = c(16, 21, 12, 10, 10, 6, 8, 14)
d_mh = sqrt(sum(abs(x-y)))
d_mh
```

- **Distância de Mahalanobis** é uma distância que leva em consideração a covariância entre variáveis e é uma extensão da distância euclidiana, sendo uma medida invariante à escala em que a variável foi medida, e é definida por

$$d_{mb}^2 = (\mathbf{X} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}_{\mathbf{X}}^{-1} (\mathbf{X} - \boldsymbol{\mu}),$$

sendo X a matriz de variáveis aleatórias e $\boldsymbol{\mu}$ e $\boldsymbol{\Sigma}_{\mathbf{X}}$ o vetor de médias e a matriz de covariância da matriz de dados, respectivamente. No R, podemos calcular essa distância da seguinte forma:

```
x1 = c(91, 93, 72, 87, 86, 73, 68, 87, 78, 99, 95, 76, 84, 96,
76, 80, 83, 84, 73, 74)
x2 = c(16, 6, 3, 1, 2, 3, 2, 5, 2, 5, 2, 3, 4, 3, 3, 3, 4, 3, 4, 4)
x3 = c(3, 4, 0, 3, 4, 0, 1, 2, 1, 2, 3, 3, 3, 2, 2, 2, 3, 3, 2, 2)
x4 = c(70, 88, 80, 83, 88, 84, 78, 94, 90, 93, 89, 82, 95, 94,
81, 93, 93, 90, 89, 89)
df_xy = data.frame(cbind(x1, x2, x3, x4))
mu_xy = colMeans(df_xy)
cov_xy = cov(df_xy)

d_mb = c()
for (i in 1:length(x1)) {
  d_mb[i] = (t(t(df_xy[i,] - mu_xy)) %*% solve(cov_xy) %*%
  t(df_xy[i,] - mu_xy))
}
d_mb

d_mb_R = mahalanobis(df_xy, mu_xy, cov_xy)
d_mb_R
```

3.5 Análise gráfica

3.5.1 Gráfico de dispersão

Utilizado para visualizar a relação entre duas variáveis quantitativas. É possível detectar padrões e tendências nos dados e identificar possíveis correlações entre as variáveis. No R, podemos usar os seguintes comandos:

```
x1 = 1:100
x2 = x1 + rnorm(100, mean = 0, sd = 15)
plot(x1, x2, pch = 19, col = "black", lwd = 1,
     xlab = "Idade (em ano)", ylab = "Tempo de espera (em anos)")
```

3.5.2 Histograma

Utilizado para avaliar a forma da distribuição (assimetria e curtose). Embora seja univariado, vale usar como comparativo entre duas variáveis. No R, podemos usar os seguintes comandos (o gráfico (A) refere-se à geração de números aleatórios de uma distribuição normal e o gráfico (B) refere-se à geração de números aleatórios de uma distribuição qui-quadrado):

```
x1 = rnorm(100, mean = 0, sd = 15)
x2 = rchisq(100, 5)
par(mfrow = c(1,2))
hist(x1, prob = T, main = "(A)")
hist(x2, prob = T, main = "(B)")
```

3.5.3 Gráfico de dispersão com múltiplas informações

Utilizado para visualização múltipla: dispersão, histograma, cálculo de correlações e teste de hipóteses. No R, podemos usar os seguintes comandos:

```
library(GGally)
library(ggplot2)
ggpairs(iris[,-5])+ theme_bw()
```

4 Probabilidade (e suas distribuições)

4.1 Distribuição Normal (ou Gaussiana)

A distribuição normal é uma das distribuições de probabilidade mais utilizadas na Estatística

É uma distribuição de probabilidade absolutamente contínua e, no **contexto univariado**, é parametrizada pela esperança matemática (número real μ) e pela variância (número real positivo σ^2).

Assim, se $X \sim \mathcal{N}(\mu, \sigma^2)$, então sua função densidade de probabilidade é dada por

$$f(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{1}{2\sigma^2}(x-\mu)^2\right\}$$

Importante ressaltar que se a distribuição normal tem média nula e variância unitária, então ela é chamada de distribuição normal centrada e reduzida ou de distribuição normal padrão.

No **contexto multivariado**, essa distribuição é parametrizada pela esperança matemática (vetor real $\boldsymbol{\mu}$) e pela matriz de variâncias e covariâncias (matriz positiva definida $\boldsymbol{\Sigma}$).

Assim, se $X \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, então sua função densidade de probabilidade é dada por

$$f(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{k/2}|\boldsymbol{\Sigma}|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^T\boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu})\right).$$

Para gerar valores aleatórios dessa distribuição no R, usamos os seguintes comandos

```
library(faux)
X = rnorm_multi(100, 3, c(0, .5, 1),
                r = c(0.2, -0.5, 0.5),
                varnames=c("X1", "X2", "X3"))
cor(X)
```

4.2 Distribuição Student-t

A distribuição Student-t (ou somente distribuição t) também é uma das distribuições de probabilidade mais utilizadas na Estatística.

É uma distribuição de probabilidade absolutamente contínua e, no **contexto univariado**, é parametrizada pela esperança matemática (número real μ), pela variância (número real positivo σ^2) e pelos graus de liberdade (número inteiro positivo ν)

Assim, se $X \sim \mathcal{T}(\mu, \sigma^2, v)$, então sua função densidade de probabilidade é dada por

$$f(x|\mu, \sigma^2, \nu) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\,\Gamma\left(\frac{\nu}{2}\right)(1+x^2/\nu)^{(\nu+1)/2}}$$

Essa distribuição é útil quando trabalhamos com amostras pequenas, é mais robusta em relação a outliers e variações extremas nos dados, à medida que o tamanho da amostra aumenta, essa distribuição se aproxima da distribuição normal (ou seja, para amostras grandes, podemos usar a distribuição normal como uma aproximação da distribuição t.

No contexto multivariado, essa distribuição é parametrizada pela esperança matemática (vetor real $\boldsymbol{\mu}$), pela matriz de variâncias e covariâncias (matriz positiva definida $\boldsymbol{\Sigma}$) e pelos graus de liberdade (número inteiro positivo ν).

Assim, se $X \sim \mathcal{T}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, então sua função densidade de probabilidade é dada por

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{n/2}|\boldsymbol{\Sigma}|^{1/2}} \left(1 + \frac{(\mathbf{x}-\mu)^T \boldsymbol{\Sigma}^{-1}(\mathbf{x}-\mu)}{\nu}\right)^{-\frac{\nu+n}{2}},$$

onde $\mathbf{X}$ é a matriz de dados observada, $\boldsymbol{\mu}$ é o vetor de médias, $\boldsymbol{\Sigma}$ é a matriz de covariância, k é o número de variáveis e ν é o número de graus de liberdade (que determina a forma da distribuição).

Para gerar valores aleatórios dessa distribuição no R, usamos os seguintes comandos

```
library(faux)
library(LaplacesDemon)
x <- seq(-2,4,length=21)
y <- 2*x+10
z <- x+cos(y)
mu <- c(1,12,2)
S <- matrix(c(1,2,0,
              2,5,0.5,
              0,0.5,3), 3, 3)
df <- 4
X <- rmvt(1000, c(0,1,2), S, 5)
head(X)
cor(X)
```

5 Inferência

5.1 Conceitos prévios

Teorema do Limite Central. Sejam $\mathbf{X}_1, \mathbf{X}_2, \ldots, \mathbf{X}_n$ uma amostra de vetores de variáveis aleatórias i.i.d., de uma distribuição qualquer p-variada, com média $\mathbb{E}(\mathbf{X}_i) = \boldsymbol{\mu}$ e matriz de variâncias e covariâncias $\mathrm{Var}(\mathbf{X}_i) = \boldsymbol{\Sigma}$, para $i = 1, 2, ..., n$ e $\boldsymbol{\Sigma}$ positiva definida. Então, para n suficientemente grande, temos que

$$\sqrt{n}(\bar{\mathbf{X}} - \boldsymbol{\mu}) \sim N_p(\mathbf{0}, \Sigma),$$

ou seja, a distribuição de $\sqrt{n}(\bar{\mathbf{X}} - \boldsymbol{\mu})$ se aproxima de uma distribuição normal multivariada $N(\mathbf{0}, \boldsymbol{\Sigma})$, onde $\bar{\mathbf{X}} = \frac{1}{n}\sum_{i=1}^{n} \mathbf{X}_i$ e, ainda,

$$n(\bar{\mathbf{X}} - \boldsymbol{\mu})^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu}) \sim \chi^2(p).$$

5.2 Sobre o vetor de médias de uma população

Sejam $\mathbf{X}_1, \mathbf{X}_2, \ldots, \mathbf{X}_p$ uma amostra aleatória de uma distribuição $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, estamos interessados em testar

$$\begin{aligned} H_0: &\quad \boldsymbol{\mu} = \boldsymbol{\mu}_0 \\ H_1: &\quad \boldsymbol{\mu} = \boldsymbol{\mu}_0, \end{aligned}$$

sendo $\boldsymbol{\mu}_0$ um vetor de médias qualquer a ser considerado.

Para realizar esse teste, utilizamos o fato de que $\bar{\mathbf{X}}$ é o vetor de médias amostrais e $\mathbf{S}$ é a matriz de variâncias e covariâncias amostrais e que

- $\bar{\mathbf{X}} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}/n)$
- $(n-1)\mathbf{S} \sim \mathrm{Wishart}(n-1)$
- $\bar{\mathbf{X}}$ e $\mathbf{S}$ são independentes.

Considerando H_0 verdadeira, temos que a estatística do teste e sua respectivamente distribuição são dadas por

$$T^2 = \sqrt{n}(\bar{\mathbf{X}} - \mu_0)^\top \left(\frac{(n-1)S}{n-1}\right) \sqrt{n}(\bar{\mathbf{X}} - \mu_0) \sim \left(\frac{(n-1)p}{n-p}\right) F(p, n-p),$$

em que $q_{F(p,n-p),\alpha}$ é o quantil α-superior da distribuição $F(p, n-p)$

Assim, rejeitamos H_0, a um nível de significância α, se

$$T^2_{obs} > \frac{(n-1)p}{n-p} q_{F(p,n-p),\alpha}.$$

Vale ressaltar que estatística do teste para este caso é chamada estatística T^2 de Hotelling, que é uma generalização do teste T de médias para o caso univariado.

Além do teste de hipóteses, podemos estar interessados no intervalo de confiança para esse vetor de médias. Porém, como estamos no contexto multivariado, substituimos o intervalo pela chamada região de confiança.

Assim, sejam $\mathbf{X}_1, \mathbf{X}_2, \ldots, \mathbf{X}_n$ uma amostra aleatória de uma distribuição $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, uma região com $(1-\alpha) \times 100\%$ de confiança para $\boldsymbol{\mu}$ é dada pelo elipsoide determinado pelos valores de μ^* que satisfazem

$$n(\bar{\mathbf{X}} - \boldsymbol{\mu}^*)^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu}^*) \leq \frac{(n-1)p}{n-p} F(p, n-p) = c$$

Assim, para verificar se μ_0 está dentro da região de confiança, verificamos se

$$n(\bar{\mathbf{X}} - \boldsymbol{\mu}_0^*)^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu}_0^*) \leq \frac{(n-1)p}{n-p} F(p, n-p),$$

caso seja, μ_0 está dentro da região de confiança.

5.3 Sobre o vetor de médias de duas populações independentes

Sejam $\mathbf{X}_{11}, \mathbf{X}_{12}, \ldots, \mathbf{X}_{1n}$ uma amostra aleatória de uma distribuição $\mathcal{N}_p(\boldsymbol{\mu}_1, \Sigma)$ e $\mathbf{X}_{21}, \mathbf{X}_{22}, \ldots, \mathbf{X}_{2n}$ uma amostra aleatória de uma distribuição $\mathcal{N}_p(\boldsymbol{\mu}_2, \Sigma)$ retiradas de populações diferentes

Neste caso, ambas as populações são normais e têm a mesma matriz de covariância, que é estimada por

$$S_{pooled} = \frac{(n_1-1)S_1 + (n_2-1)S_2}{n_1+n_2-2} = \frac{\sum_{j=1}^{n_1}(\mathbf{X}_{1j} - \bar{\mathbf{X}}_1)(\mathbf{X}_{1j} - \bar{\mathbf{X}}_1)^\top + \sum_{j=1}^{n_2}(\mathbf{X}_{2j} - \bar{\mathbf{X}}_2)(\mathbf{X}_{2j} - \bar{\mathbf{X}}_2)^\top}{n_1+n_2-2}$$

O interesse consiste em avaliar se não há diferença entre entre os dois vetores de médias coletados, ou seja, desejamos testar

$$\begin{aligned} H_0: &\quad \boldsymbol{\mu}_1 = \boldsymbol{\mu}_2 \\ H_1: &\quad \boldsymbol{\mu}_1 \neq \boldsymbol{\mu}_2, \end{aligned}$$

que em um caso mais geral, é dada por

$$\begin{aligned} H_0: &\quad \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2 = \boldsymbol{\delta}_0 \\ H_1: &\quad \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2 \neq \boldsymbol{\delta}_0 \end{aligned}$$

Rejeitamos H_0 ao nível de significância de α se

$$T_{obs}^2 = (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - \boldsymbol{\delta}_0)^\top \left[\left(\frac{1}{n} + \frac{1}{n}\right)\mathbf{S}\right]^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - \boldsymbol{\delta}_0) > \frac{(n_1+n_2-2)p}{n_1+n_2-p-1} q_{F(n_1+n_2-p-1,\alpha)}.$$

Note que $\mathbb{E}(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2) = \mathbb{E}(\bar{\mathbf{X}}_1) - \mathbb{E}(\bar{\mathbf{X}}_2) = \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2$, $\mathrm{Var}(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2) = \mathrm{Var}(\bar{\mathbf{X}}_1) + \mathrm{Var}(\bar{\mathbf{X}}_2)$. Então,

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 \sim \mathcal{N}_p\left(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2, \left(\frac{1}{n_1} + \frac{1}{n_2}\right)\Sigma\right)$$

Para verificar se μ_0 estã dentro da região de confiança $100(1-\alpha)\%$, verificamos se

$$n(\bar{\mathbf{d}} - \boldsymbol{\mu}_D^*)^\top \mathbf{S}_D^{-1}(\bar{\mathbf{d}} - \boldsymbol{\mu}_D^*) \leq \frac{(n-1)p}{n-p} F(p, n-p),$$

caso seja, μ_D está dentro da região de confiança

5.4 Sobre o vetor de médias de populações paredas (medidas repetidas)

Sejam $\mathbf{X}_{11}, \mathbf{X}_{12}, \ldots, \mathbf{X}_{1n}$ uma amostra aleatória de uma distribuição $\mathcal{N}_p(\boldsymbol{\mu}_1, \Sigma)$ e $\mathbf{X}_{21}, \mathbf{X}_{22}, \ldots, \mathbf{X}_{2n}$ uma amostra aleatória de uma distribuição $\mathcal{N}_p(\boldsymbol{\mu}_2, \Sigma)$ retiradas de uma mesma população, mas em diferentes momentos (momento 1 e momento 2 ou momento antes e momento depois, respectivamente).

O interesse é consiste em avaliar se não há diferença entre entre os dois vetores de médias coletados, ou seja, desejamos testar

$$\begin{aligned} H_0 &: \boldsymbol{\mu}_1 = \boldsymbol{\mu}_2 \\ H_1 &: \boldsymbol{\mu}_1 \neq \boldsymbol{\mu}_2. \end{aligned}$$

Para isso, consideramos as diferenças $\mathbf{D}_j = \mathbf{X}_{1j} - \mathbf{X}_{2j}$, que implica que $\mathbf{D}_1, \mathbf{D}_2, ..., \mathbf{D}_n$ são iid e que $\mathbf{D}_j \sim \mathcal{N}_p(\boldsymbol{\mu}_D, \boldsymbol{\Sigma}_D)$. Logo, o teste se reduz a

$$\begin{aligned} H_0 &: \boldsymbol{\mu}_D = \mathbf{0} \\ H_1 &: \boldsymbol{\mu}_D \neq \mathbf{0}, \end{aligned}$$

com a estatística T^2 de Hotelling dada, sob H_0, por

$$T^2 = n(\bar{\mathbf{D}} - 0)^\top \mathbf{S}_D^{-1}(\bar{\mathbf{D}} - 0) \sim \left(\frac{(n-1)p}{n-p}\right) F(p, n-p),$$

sendo

Caso o interesse esteja em comparar a diferença para um valor específico, podemos fazer

$$\begin{aligned} H_0 &: \boldsymbol{\mu}_D = \boldsymbol{\mu}_{D_0} \\ H_1 &: \boldsymbol{\mu}_D \neq \boldsymbol{\mu}_{D_0}, \end{aligned}$$

com a estatística T^2 de Hotelling dada, sob H_0, por

$$T^2 = n(\bar{\mathbf{D}} - \boldsymbol{\mu}_{D_0})^\top \mathbf{S}_D^{-1}(\bar{\mathbf{D}} - \boldsymbol{\mu}_{D_0}) \sim \left(\frac{(n-1)p}{n-p}\right) F(p, n-p),$$

sendo

Para verificar se $\boldsymbol{\mu}_0$ estão dentro da região de confiança $100(1-\alpha)\%$, verificamos se

$$n(\bar{\mathbf{d}} - \boldsymbol{\mu}_D^*)^\top \mathbf{S}_D^{-1}(\bar{\mathbf{d}} - \boldsymbol{\mu}_D^*) \leq \frac{(n-1)p}{n-p} F(p, n-p),$$

caso seja, $\boldsymbol{\mu}_D$ está dentro da região de confiança

5.5 Sobre o vetor de médias de mais de uma população (MANOVA)

Sejam $\mathbf{X}_{11}, \mathbf{X}_{12}, \ldots, \mathbf{X}_{1n_1}$ uma amostra aleatória de uma distribuição $\mathcal{N}_p(\boldsymbol{\mu}_1, \Sigma)$, $\mathbf{X}_{21}, \mathbf{X}_{22}, \ldots, \mathbf{X}_{2n_2}$ uma amostra aleatória de uma distribuição $\mathcal{N}_p(\boldsymbol{\mu}_2, \Sigma)$, ..., $\mathbf{X}_{g1}, \mathbf{X}_{g2}, \ldots, \mathbf{X}_{gn_g}$ uma amostra aleatória de uma distribuição $\mathcal{N}_p(\boldsymbol{\mu}_g, \Sigma)$ (retiradas de populações diferentes e indenpendentes entre si, estamos interessados em testar

$$\begin{aligned} H_0 &: \quad \boldsymbol{\mu}_1 = \boldsymbol{\mu}_2 = ... = \boldsymbol{\mu}_g \\ H_1 &: \quad \text{pelo menos um } \boldsymbol{\mu}_i \text{ é diferente.} \end{aligned}$$

Para facilitar os cálculos e apresentações dos resultados, reparametrizamos a média do grupo k da seguinte forma

$$\boldsymbol{\mu}_k = \boldsymbol{\mu} + \boldsymbol{\tau}_k, \qquad k = 1, 2, ..., g,$$

onde $\boldsymbol{\tau}_k$ é o efeito do grupo k. Dessa forma, estamos interessados em testar

$$\begin{aligned} H_0: &\quad \boldsymbol{\tau}_1 = \boldsymbol{\tau}_2 = ... = \boldsymbol{\tau}_g = 0 \\ H_1: &\quad \text{pelo menos um } \boldsymbol{\tau}_i \text{ é diferente de zero.} \end{aligned}$$

Para realizar esse teste, decompomos a observação $\mathbf{X}_{kj}$ em termos de uma média geral ($\boldsymbol{\mu}$), do efeito do k-ésimo tratamento ($\boldsymbol{\tau}_k$) e de um erro aleatório ($\boldsymbol{\epsilon}_{kj}$), ou seja,

$$\mathbf{X}_{kj} = \boldsymbol{\mu} + \boldsymbol{\tau}_k + \boldsymbol{\epsilon}_{kj},$$

para $j = 1, 2, ..., n_k$ e $k = 1, 2, ..., g$, com $\boldsymbol{\epsilon}_{kj} \sim \mathcal{N}_p(\mathbf{0}, \boldsymbol{\Sigma})$.

Se desenvolvermos a decomposição dada por $\mathbf{X}_{kj} = \boldsymbol{\mu} + \boldsymbol{\tau}_k + \boldsymbol{\epsilon}_{kj}$, conseguimos expressar a variabildiade dos dados em torno da média em variabilidade intra e entre tratamentos, ou seja,

$$SQ_{total} = SQ_{trat} + SQ_{res}$$

sendo SQ_{total} a soma de quadrados e produtos cruzados total, SQ_{trat} a soma de quadrados e produtos cruzados entre tratamentos e SQ_{res} a soma de quadrados e produtos cruzados intra (dentro) tratamentos dados, respectivamente por

- $SQ_{total} = \sum_{k=1}^{g} \sum_{j=1}^{n_k} (\mathbf{X}_{jk} - \bar{\mathbf{X}})(\mathbf{X}_{jk} - \bar{\mathbf{X}})^\top$
- $SQ_{trat} = \sum_{k=1}^{g} n_k (\bar{\mathbf{X}}_k - \bar{\mathbf{X}})(\bar{\mathbf{X}}_k - \bar{\mathbf{X}})^\top$
- $SQ_{res} = \sum_{k=1}^{g} \sum_{j=1}^{n_k} (\bar{\mathbf{X}}_{kj} - \bar{\mathbf{X}}_k)(\bar{\mathbf{X}}_{kj} - \bar{\mathbf{X}}_k)^\top$.

O teste de hipóteses, nesse caso, se reduz a avaliar o quanto SQ_{res} é pequeno em relação a SQ_{total}, pois se todas as médias foram consideradas iguais, pouca informação irá sobrar para o resíduo. Para medir essa relação, usamos o chamado lambda de Wilks, que é uma generalização multivariada do teste F univariado.

Considerando H_0 verdadeira, temos que a estatística do teste e sua respectiva distribuição são dadas por

$$\Lambda^* = \frac{|SQ_{res}|}{|SQ_{res} + SQ_{trat}|},$$

com $-\left(n - 1 - \frac{p+g}{2}\right) \log(\Lambda^*) \sim \chi^2_p(g-1)$.

6 Técnicas multivariadas I (redução de dimensionalidade)

A redução de dimensionalidade se refere ao processo de reduzir o número de variáveis em um conjunto de dados, mantendo o máximo possível das informações originais. Existem várias razões pelas quais você pode querer reduzir a dimensionalidade dos dados:, dentre elas destacam-se:

- Eliminação de ruído e redundância (princípio da parcimônia);
- Simplificação e interpretabilidade;
- Visualização (projetar os dados em um espaço de menor dimensão).

Na literatura, existem duas abordagens principais para a redução de dimensionalidade:

- **Seleção de variáveis:** envolve selecionar um subconjunto das variáveis originais do conjunto de dados, consideradas as mais importantes para explicar a variabilidade nos dados;
- **Extração de variáveis:** as variáveis originais são transformadas em um novo conjunto de variáveis, geralmente de menor dimensão, que são combinações lineares das variáveis originais, escolhidas de forma a capturar a maior parte da variabilidade nos dados.

As abordagens de **extração de variáveis** serão o foco dos nossos estudos nessa seção e, dentre elas, vamos dicutir o método de Análise de Componentes Principais (PCA) e o método de Análise Fatorial (AF).

6.1 Análise de componentes principais

6.1.1 Conceitos iniciais

A **Análise de Componentes Principais (ACP)**, inicialmente proposta por Karl Pearson em 1901 e estudada e nomeada por Harold Hotelling em 1933, é uma técnica que transforma linearmente um conjunto de p variáveis correlacionadas em um conjunto de p variáveis não correlacionadas.

Essa transformação nos permite que, ao invés de trabalhar com p variáveis, seja possível trabalhar com somente k dessas variáveis, tal que $k < p$, que são capazes de explicar uma parcela substancial das informações do conjunto original de p variáveis.

Os objetivos ao se usar a ACP são:

- Redução de dimensionalidade (variáveis não correlacionadas);
- Obter combinações interpretáveis das variáveis originais;
- Descrever e/ou compreender a estrutura de correlação das variáveis originais.

6.1.2 Contexto estatístico

Nessa seção, vamos estudar a ACP sob o ponto de vista estatístico, ou seja, ACP que tenham propriedades estatísticas. Assim, vamos considerar que se as variáveis originais tiverem distribuição normal multivariada, as componentes principais serão independentes entre si e também terão distribuição normal multivariada.

Para explanação dos conceitos durante nossos estudos, vamos seguir duas abordagens de obtenção das componentes principais:

- Obtenção das componentes principais a partir da matriz de covariância (populacional e amostral);

- Obtenção das componentes principais a partir da matriz de correlação (populacional e amostral).

Assim, seja $\mathbf{X}_{p\times 1}$ um vetor aleatório com vetor de médias (populacionais) $\boldsymbol{\mu}_{p\times 1}$ e matriz de variâncias e covariâncias (populacionais) $\boldsymbol{\Sigma}_{p\times p}$. Estamos particularmente interessados no caso em que as variáveis $\mathbf{X}_1, ..., \mathbf{X}_p$ estão correlacionadas, isto é, existe $\mathrm{Cov}(X_i, X_j)$ não-nulas, para $i, j = 1, ..., p$ e $i \neq j$. Graficamente, podemos representar esse questionamento da seguninte forma:

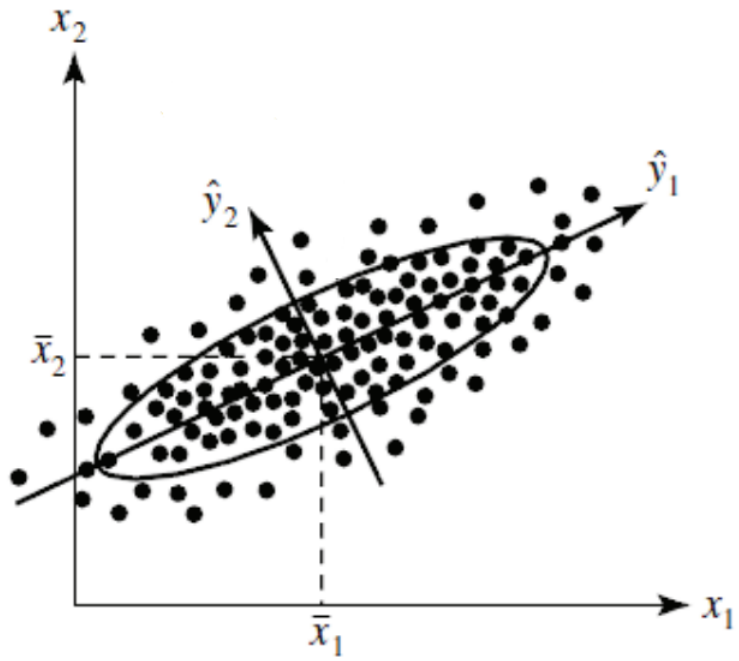

Figura 1: Representação gráfica da ACP.

Quando isso ocorre, existe redundância entre dimensões e podemos ter interesse em reduzir a dimensionalidade do problema, construindo novas variáveis, não correlacionadas entre si, que sejam **combinações lineares das variáveis originais**.

Pode ser que poucas (k) novas variáveis expliquem grande parte da variabilidade existente nas (p) variáveis originais. Isso pode significar a redução de custos como tempo computacional e espaço para armazenamento de dados.

6.1.3 ACP via matriz de covariância

Seja $\mathbf{X}_{p\times 1}$ um vetor aleatório com vetor de médias (populacionais) $\boldsymbol{\mu}_{p\times 1}$ e matriz de covariâncias (populacionais) $\boldsymbol{\Sigma}_{p\times p}$ que segue uma distribuição qualquer, que denotamos por $\mathbf{X} \sim (\boldsymbol{\mu}, \boldsymbol{\Sigma})$.

A ideia da **ACP via matriz de covariância** é decompor a matriz $\boldsymbol{\Sigma}$ em autovalores e autovetores, tais $\lambda_1, \lambda_2, ..., \lambda_p$ são os seus autovalores e $\mathbf{e}_1, \mathbf{e}_2, ..., \mathbf{e}_p$ são os seus autovetores, que obedecem às seguintes condições:

- $\lambda_1 \geq ... \geq \lambda_p$;
- $\mathbf{e}_i^\top \mathbf{e}_j = 0$, $i, j = 1, ..., p$ e $i \neq j$ (os vetores são ortogonas entre si);
- $\mathbf{e}_i^\top \mathbf{e}_i = 1$, $i, j = 1, ..., p$;
- $\boldsymbol{\Sigma}\mathbf{e}_i = \lambda_i \mathbf{e}_i$, $i, j = 1, ..., p$.

Para isso, considere a matriz ortogonal $\mathbf{O}_{p\times p}$, tal que $\mathbf{O} = (\mathbf{e}_1, \mathbf{e}_2, ..., \mathbf{e}_p)$ é um matriz formada pelos autovetores de $\mathbf{\Sigma}$. Então, podemos reescrever $\mathbf{Y}_{p\times 1}$ de tal forma que

$$\mathbf{Y}_{p\times 1} = \mathbf{O}_{p\times p}^\top \mathbf{X}_{p\times 1},$$

que obedece ao fato de que $\mathbf{e}_1$ é o autovetor correspondente ao maior autovalor de $\mathbf{\Sigma}$ (dado por λ_1), $\mathbf{e}_2$ é o autovetor correspondente ao segundo maior autovalor de $\mathbf{\Sigma}$ (dado por λ_2) e assim sucessivamente.

Ou seja, cada componente principal será uma combinação linear dos elementos de $\mathbf{X}$, mas as entradas da combinação linear são os elementos dos autovetores correspondentes aos autovalores de $\mathbf{\Sigma}$.

Essa decomposição apresenta as seguintes propriedades:

- A j-ésima componente principal de $\mathbf{\Sigma}$ é dada por $\mathbf{Y}_j = \mathbf{e}_j^\top \mathbf{X}$;
- $\mathbb{E}(\mathbf{Y}_j) = \mathbb{E}(\mathbf{e}_j^\top \mathbf{X}) = \mathbf{e}_j^\top \mathbb{E}(\mathbf{Y}_j) = \mathbf{e}_j^\top \boldsymbol{\mu}$;
- $\mathrm{Var}(\mathbf{Y}_j) = \mathrm{Var}(\mathbf{e}_j^\top \mathbf{X}) = \mathbf{e}_j^\top \mathbf{\Sigma} \mathbf{e}_j = \lambda_j \mathbf{e}_j^\top \mathbf{e}_j = \lambda_j$;
- $\mathrm{Cov}(\mathbf{Y}_i, \mathbf{Y}_j) = \mathrm{Cor}(\mathbf{Y}_i, \mathbf{Y}_j) = 0$, $i, j = 1, ..., p$ e $i \neq j$;
- A proporção da variância total de $\mathbf{X}$ e que é explicada pela j-ésima componente principal é $\frac{\lambda_j}{\sum_{i=1}^p \lambda_i}$.

Porém, como em geral a matriz $\mathbf{\Sigma}$ é desconhecida, utiliza-se a matriz $\mathbf{S}$, de covariâncias amostrais, para estimar as componentes principais. A ideia é a mesma, ou seja, decompor a matriz $\mathbf{S}$ em autovalores e autovetores, tais $\hat{\lambda}_1, \hat{\lambda}_2, ..., \hat{\lambda}_p$ são os seus autovalores e $\hat{\mathbf{e}}_1, \hat{\mathbf{e}}_2, ..., \hat{\mathbf{e}}_p$ são os seus autovetores, que obedecem às seguintes propriedades:

- A j-ésima componente principal de $\mathbf{S}$ é dada por $\hat{\mathbf{Y}}_j = \hat{\mathbf{e}}_j^\top \mathbf{X}$;
- $\mathrm{Var}(\hat{\mathbf{Y}}_j) = \mathrm{Var}(\hat{\mathbf{e}}_j^\top \mathbf{X}) = \hat{\mathbf{e}}_j^\top \mathbf{\Sigma} \hat{\mathbf{e}}_j = \hat{\lambda}_j \hat{\mathbf{e}}_j^\top \hat{\mathbf{e}}_j = \hat{\lambda}_j$;
- $\mathrm{Cov}(\hat{\mathbf{Y}}_i, \hat{\mathbf{Y}}_j) = \mathrm{Cor}(\hat{\mathbf{Y}}_i, \hat{\mathbf{Y}}_j) = 0$, $i, j = 1, ..., p$ e $i \neq j$;
- A proporção da variância total de $\mathbf{X}$ e que é explicada pela j-ésima componente principal é $\frac{\hat{\lambda_j}}{\sum_{i=1}^p \hat{\lambda_i}}$;

É comum utilizar os escores das componentes para análises estatísticas ou ordenação (ranking) dos elementos amostrais. Esses escores são obtidos ordenando os valores obtidos de

$$\hat{\mathbf{Y}}_j = \hat{\mathbf{e}}_j^\top \mathbf{X}.$$

6.1.4 ACP via matriz de correlação

Caso esteja lidando com variáveis que tenham magnitude diferente e não queremos que isso influencie nos resultados, usamos a decomposição a partir da matriz de correlação dos dados (às vezes pode ser de interesse manter essas variáveis, a fim de estudar o comportamento dessas variáveis com maior variabildade).

Seja $\mathbf{X}_{p\times 1}$ um vetor aleatório com vetor de médias (populacionais) $\boldsymbol{\mu}_{p\times 1}$ e matriz de covariâncias (populacionais) $\mathbf{\Sigma}_{p\times p}$, denotado por $\mathbf{X} \sim (\boldsymbol{\mu}, \mathbf{\Sigma})$. A ideia da **ACP via matriz de correlação** consiste em padronizar cada variável X_i na forma

$$Z_i = \frac{X_i - \mu_i}{\sigma_i},$$

sendo $Z = (Z_1, ..., Z_p)^\top$, em que $\mu_i = \mathbb{E}(X_i)$ e $\sigma_i^2 = \mathrm{Var}(X_i)$, tal que $\mathrm{Cov}(\mathbf{Z}) = \mathbf{P} = \mathrm{Cor}(X)$, e decompor a matriz $\mathbf{P}$ em autovalores e autovetores, tais $\lambda_1, \lambda_2, ..., \lambda_p$ são os seus autovalores e $\mathbf{e}_1, \mathbf{e}_2, ..., \mathbf{e}_p$ são os seus autovetores, que obedecem às seguintes condições:

- $\lambda_1 \geq ... \geq \lambda_p$;
- $\mathbf{e}_i^\top \mathbf{e}_j = 0$, $i, j = 1, ..., p$ e $i \neq j$ (os vetores são ortogonas entre si);
- $\mathbf{e}_i^\top \mathbf{e}_i = 1$, $i, j = 1, ..., p$;
- $\boldsymbol{\Sigma}\mathbf{e}_i = \lambda_i \mathbf{e}_i$, $i, j = 1, ..., p$.

Para isso, considere a matriz ortogonal $\mathbf{O}_{p\times p}$, tal que $\mathbf{O} = (\mathbf{e}_1, \mathbf{e}_2, ..., \mathbf{e}_p)$ é um matriz formada pelos autovetores de $\mathbf{P}$. Então, podemos reescrever $\mathbf{Y}_{p\times 1}$ de tal forma que

$$\mathbf{Y}_{p\times 1} = \mathbf{O}_{p\times p}^\top \mathbf{Z}_{p\times 1},$$

que obedece ao fato de que $\mathbf{e}_1$ é o autovetor correspondente ao maior autovalor de $\mathbf{P}$ (dado por λ_1), $\mathbf{e}_2$ é o autovetor correspondente ao segundo maior autovalor de $\mathbf{P}$ (dado por λ_2) e assim sucessivamente.

Ou seja, cada componente principal será uma combinação linear dos elementos de $\mathbf{X}$, mas as entradas da combinação linear são os elementos dos autovetores correspondentes aos autovalores de $\mathbf{P}$.

Essa decomposição apresenta as seguintes propriedades:

- A j-ésima componente principal de $\mathbf{P}$ é dada por $\mathbf{Y}_j = \mathbf{e}_j^\top \mathbf{Z}$;
- $\mathbb{E}(\mathbf{Y}_j) = \mathbb{E}(\mathbf{e}_j^\top \mathbf{X}) = \mathbf{e}_j^\top \mathbb{E}(\mathbf{Y}_j) = \mathbf{e}_j^\top \boldsymbol{\mu}$;
- $\mathrm{Var}(\mathbf{Y}_j) = \mathrm{Var}(\mathbf{e}_j^\top \mathbf{X}) = \mathbf{e}_j^\top \boldsymbol{\Sigma}\mathbf{e}_j = \lambda_j \mathbf{e}_j^\top \mathbf{e}_j = \lambda_j$;
- $\mathrm{Cov}(Y_i, Y_j) = \mathrm{Cor}(Y_i, Y_j) = 0$, $i, j = 1, ..., p$ e $i \neq j$;
- A proporção da variância total de $\mathbf{Z}$ e que é explicada pela j-ésima componente principal é $\frac{\lambda_j}{p}$ (na matriz de correlação, a diagonal principal é formada por uns, então como temos p variáveis, temos p no denominador).

Porém, como em geral a matriz $\mathbf{P}$ é desconhecida, utiliza-se a matriz $\mathbf{R}$, de correlações amostrais, para estimar as componentes principais. Nesse caso, teremos as seguintes propriedades:

- A j-ésima componente principal de $\mathbf{R}$ é dada por $\hat{\mathbf{Y}}_j = \hat{\mathbf{e}}_j^\top \mathbf{Z}$;
- $\mathrm{Var}(\hat{\mathbf{Y}}_j) = \hat{\lambda}_j$;
- $\mathrm{Cov}(\hat{\mathbf{Y}}_i, \hat{\mathbf{Y}}_j) = \mathrm{Cor}(\hat{\mathbf{Y}}_i, \hat{\mathbf{Y}}_j) = 0$, $i, j = 1, ..., p$ e $i \neq j$;
- A proporção da variância total de $\mathbf{X}$ e que é explicada pela j-ésima componente principal é $\frac{\hat{\lambda}_j}{p}$;

É comum utilizar os escores das componentes para análises estatísticas ou ordenação (ranking) dos elementos amostrais. Esses escores são obtidos ordenando os valores obtidos de

$$\hat{\mathbf{Y}}_j = \hat{\mathbf{e}}_j^\top \mathbf{Z}.$$

6.1.5 Determinação do número de componentes principais

- Proporção da variância total explicada;
- Análise gráfica da variância explicada (scree-plot ou gráfico de cotovelo);
- Análise prática das componentes principais.

6.2 Análise Fatorial

6.2.1 Conceitos iniciais

Assim como a Análise de componentes principais, a **Análise Fatorial (AF)**, proposta por Charles Spearman em 1904, também é uma técnica de redução de dimensionalidade de acordo com a variabilidade original do vetor aleatório $\mathbf{X}_{p\times 1}$ em termos de um número menor m de variáveis aleatórias, mas cujas componentes, chamadas de fatores comuns, são variáveis latentes, que estão relacionadas com $\mathbf{X}$ por meio de um modelo linear.

Os objetivos da AF são:

- Agrupar as variáveis originais de $\mathbf{X}_i$, $i = 1, .., p$, em fatores mutuamente não correlacionados e interpretáveis;
- Reduzir a dimensionalidade do problema.

Além disso, vale ressaltar que essa técnica é divida em duas diferentes abordagens:

- Análise Fatorial Exploratória (AFE);
- Análise Fatorial Confirmatória (AFC).

6.2.2 Estrutura

Sejam $\mathbf{X}_{p\times 1}$ um vetor aleatório com $\mathbb{E}(\mathbf{X}) = \boldsymbol{\mu}$, $\mathrm{Var}(\mathbf{X}) = \boldsymbol{\Sigma}$, $\mathrm{Cor}(\mathbf{X}) = \mathbf{P}$ e

$$Z_i = \frac{X_i - \mu_i}{\sigma_1},$$

para $i = 1, ..., p$ tal que $\mathrm{Cov}(\mathbf{Z}) = \mathbf{P} = \mathrm{Cor}(\mathbf{X})$

Queremos explicar as variáveis padronizadas $\mathbf{Z}_1, ..., \mathbf{Z}_p$ com m fatores $\mathbf{F}_1, ..., \mathbf{F}_m$, de tal forma que:

$$\mathbf{Z} = \mathbf{LF} + \boldsymbol{\epsilon},$$

cuja estrutura matricial pode ser apresentada pela seguinte expressão

$$\begin{aligned}
\mathbf{Z}_1 &= l_{11}\mathrm{F}_1 + ... + l_{1m}\mathrm{F}_m + \epsilon_1 \\
\mathbf{Z}_2 &= l_{21}\mathrm{F}_1 + ... + l_{2m}F_m + \epsilon_2 \\
&\vdots \\
\mathbf{Z}_p &= l_{p1}\mathrm{F}_1 + ... + l_{pm}\mathrm{F}_m + \epsilon_p,
\end{aligned}$$

sendo

- $\mathbf{F}_{m\times 1}$ um vetor aleatório que contém m fatores (também chamados de variáveis latentes, que descrevem os elementos da população e são não observáveis);
- $\boldsymbol{\epsilon}$ o vetor de erros aleatórios não observáveis (o que não conseguimos explicar);
- l_{ij}, também chamado de loading (peso) ou carga fatorial, o coeficiente da i-ésima variável padronizada Z_i, $i = 1, ..., p$ no j-ésimo fator, F_j , $j = 1, ..., m$ e $\mathbf{L}$ é a matriz de cargas fatoriais.

O modelo $\mathbf{Z} = \mathbf{LF} + \boldsymbol{\epsilon}$ é chamado de modelo fatorial ortogonal, já que os m fatores são ortogonais entre si. Essa estrutura apresenta as seguintes suposições:

- $\mathbb{E}(\mathbf{F}) = \mathbf{0}$;
- $\mathrm{Var}(\mathbf{F}) = \mathbf{I}$;
- $\mathbb{E}(\boldsymbol{\epsilon}) = \mathbf{0}$;
- $\mathrm{Var}(\boldsymbol{\epsilon}) = \boldsymbol{\Psi} = \mathsf{diag}(\Psi_1, ..., \Psi_p)$.
- $\mathbf{F}$ e $\boldsymbol{\epsilon}$ são não correlacionados

O objetivo dessa abordagem é, portanto, decompor a matriz $\mathbf{P}$ na forma

$$\mathbf{P} = \mathbf{L}_{p\times m}\mathbf{L}^{\top}_{m\times p} + \boldsymbol{\Psi}_{p\times p},$$

cuja representação é dada por

$$\mathbf{P} = \mathbf{L}\mathbf{L}^{\top} + \boldsymbol{\Psi} = \begin{pmatrix} \sum_{j=1}^{m} l_{1j}^2 & \cdots & \sum_{j=1}^{m} l_{1j}l_{jp} \\ \vdots & \ddots & \vdots \\ \sum_{j=1}^{m} l_{pj}l_{j1} & \cdots & \sum_{j=1}^{m} l_{pj}^2 \end{pmatrix} + \begin{pmatrix} \Psi_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ \vdots & \cdots & \Psi_p \end{pmatrix}.$$

Assim, vem que:

- $\mathrm{Var}(Z_i) = \sum_{j=1}^{m} l_{ij}^2 + \Psi_i = h_i^2 + \Psi_i = 1$, em que h_i^2 é chamado comunalidade (devido aos fatores) e Ψ_i é chamado de variância específica

Pode-se estimar $\mathbf{L}$ e $\boldsymbol{\Psi}$ utilizando alguns métodos, dentre eles:

- Método das componentes principais ou fatores principais;
- Método das componentes principais iterativo ou fatores principais iterativo;
- Método da máxima verossimilhança (com a suposição de normalidade).

6.2.3 Estimação do modelo usando o método da máxima verossimilhança

Suponha que $\mathbf{X} \sim \mathcal{N}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ e, portanto, $\mathbf{Z} \sim \mathcal{N}_p(\mathbf{0}, \mathbf{P})$. Além disso, $\mathbf{F} \sim \mathcal{N}_p(\mathbf{0}, \mathbf{I})$ e $\boldsymbol{\epsilon} \sim \mathcal{N}_p(\mathbf{0}, \boldsymbol{\Psi})$.

A função de verossimilhança considerando uma amostra aleatória de tamanho n, $\mathbf{Z}_1, ..., \mathbf{Z}_n$, é expressa por

$$L(P) = \frac{1}{(2\pi)^{np/2}|P|^n/2} \exp\left(-\frac{1}{2}\sum_{j=1}^{n} \mathbf{z}_j^{\top} P^{-1}\mathbf{z}_j\right),$$

ou seja,

$$L(P) = \frac{1}{(2\pi)^{np/2}|\mathbf{L}\mathbf{L}^{\top} + \boldsymbol{\Psi}|^n/2} \exp\left(-\frac{1}{2}\sum_{j=1}^{n} \mathbf{z}_j^{\top} (\mathbf{L}\mathbf{L}^{\top} + \boldsymbol{\Psi})^{-1}\mathbf{z}_j\right),$$

e devemos encontrar o máximo de $L(P)$ em $\mathbf{L}$ e $\boldsymbol{\Psi}$. Essa maximização é feita em termos numéricos para um valor de m fixo (o algoritmo pode não convergir e outro método pode ser considerado).

Se a suposição de normalidade é válida, o método da máxima verossimilhança pode produzir estimativas mais precisas. Se não podemos supor a normalidade multivariada, convém utilizar o método de fatores principais ou fatores principais iterativo. Vale ressaltar que diferentes valores de m podem levar a diferentes estimativas das cargas fatoriais.

A principal vantagem de utilizar o Método da Máxima Verossimilhança é possibilidade de se desenvolverem testes de hipóteses, com o objetivo de testar a adequacidade do modelo, o que não é possível através do método de Componentes Principais, devido às suas características não estatísticas.

6.2.4 Rotação ortogonal de fatores

Podemos estar interessado em aplicar transformações ortogonais aos fatores originais de modo que os novos fatores obtidos tenham interpretações mais fáceis e diretas. Graficamente, estamos interessados em fazer a seguinte rotação:

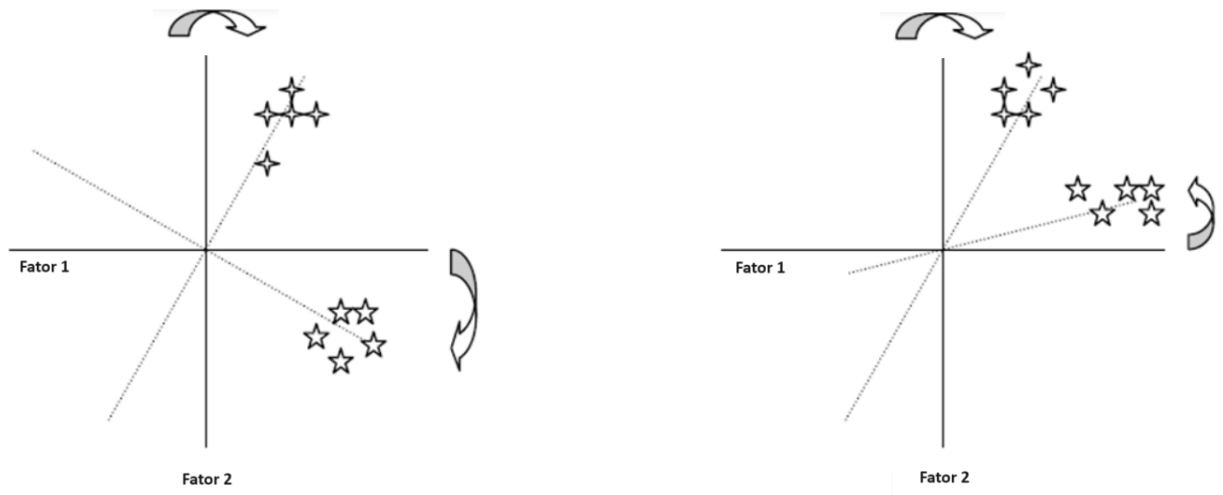

Figura 2: Representação gráfica da rotação ortogonal de fatores.

Nesse caso, a ideia consiste em considerar a matriz T ortogonal tal que $\mathbf{T}\mathbf{T}^\top = \mathbf{T}^\top\mathbf{T} = \mathbf{I}$ e rotacionar a matriz de cargas fatoriais fazendo

$$\hat{\mathbf{L}}^* = \hat{\mathbf{L}}\mathbf{T},$$

note que $\hat{\mathbf{L}}^*\hat{\mathbf{L}}^\top = (\hat{\mathbf{L}}\mathbf{T})(\hat{\mathbf{L}}\mathbf{T})^\top = \hat{\mathbf{L}}\hat{\mathbf{L}}^\top$

Os critérios para rotação ortogonal de fatores mais comumente utilizadas são:

- Varimax (Kaiser 1958): Encontrar fatores com variabilidade máxima nas cargas fatoriais;
- Quartimax (Jobson, 1996): Encontrar fatores que levem ao máximo da variabilidade dos quadrados das cargas fatoriais sobre todos os fatores;
- Orthomax (Jobson, 1996);

Os escores das componentes podem ser usados para a ordenação das observações e podem ser estimados para cada elemento amostral a partir de duas possíveis estratégias:

- Mínimos quadrados ponderados

  $$\hat{F}_j = (\hat{\mathbf{L}}^\top\mathbf{\Psi}\hat{\mathbf{L}})^{-1}(\hat{\mathbf{L}}^\top\mathbf{\Psi})\mathbf{z}_j,$$

  para $j = 1, ..., n$.

- Método de regressão

  $$\hat{F}_j = \hat{\mathbf{L}}^\top\hat{\mathbf{P}}^{-1}\mathbf{z}_j,$$

  para $j = 1, ..., n$.

6.2.5 Critérios para a escolha do número de fatores

- Análise da proporção da variância,
- Número de autovalores de R maiores do que 1,
- Gráfico scree-plot

6.3 Análise de correlação canônica

6.3.1 Conceitos iniciais

A Análise de Correlação Canônica (CCA, em inglês) é uma técnica estatística multivariada utilizada para investigar a relação entre dois conjuntos de variáveis. Ela busca encontrar uma combinação linear em cada conjunto de variáveis, atribuindo pesos a cada uma delas, de tal forma que a correlação entre as combinações lineares seja maximizada.

Assim, ao aplicarmos esses pesos às variáveis originais, chegaremos a um escore para o primeiro conjunto de variáveis e um escore para o segundo conjunto de variáveis que terão, entre si, correlação máxima. Esta técnica correspondente à Análise Fatorial no que diz respeito à criação da composição das variáveis.

Como em qualquer análise estatística, este modelo possui algumas suposições que devem ser atendidas para se obter um resultado confiável:

- Linearidade;
- Ausência de multicolinearidade;
- Normalidade.

6.3.2 Estrutura

Dada duas matrizes de dados, $\mathbf{X}_{p\times 1}$ e $\mathbf{Y}_{q\times 1}$, as variáveis canônicas dessas duas variáveis originais são dadas, respectivamente, por

$$\mathbf{U} = \mathbf{a}^\top \mathbf{X} \quad \text{e} \quad \mathbf{V} = \mathbf{b}^\top \mathbf{Y}, \tag{1}$$

em que $\mathbf{a}$ e $\mathbf{b}$ são os coeficientes lineares atribuídos, respectivamente, a $\mathbf{X}$ e a $\mathbf{Y}$, definidos de tal forma que a correlação entre $\mathbf{U}$ e $\mathbf{V}$ seja máxima.

Dessa forma, definimos como $\mathbf{U}_1$ e $\mathbf{V}_1$ o primeiro par de variáveis canônicas, tais que

$$\mathbf{U}_1 = \mathbf{a}_1^\top \mathbf{X} \quad \text{e} \quad \mathbf{V}_1 = \mathbf{b}_1^\top \mathbf{Y}, \tag{2}$$

em que $\mathbf{a}_1$, de dimensão $p \times 1$ e b_1, de dimensão $q \times 1$, são os coeficientes lineares atribuídos, respectivamente, a $\mathbf{X}$ e a $\mathbf{Y}$, para obtenção de $\mathbf{U}_1$ e $\mathbf{V}_1$.

Como precisamos encontrar a relação entre os dois conjuntos, obdecendo o fato de que as combinações lineares (variáveis canônicas) maximizem a correlação entre os conjuntos de variáveis, então estamos diante de um problema de maximização. Para o primeiro par de variáveis canônicas $(\mathbf{U}_1, \mathbf{V}_1)$, queremos obter

$$\max_{\mathbf{a},\mathbf{b}} \text{Cor}(\mathbf{U}_1, \mathbf{V}_1) = \rho_1, \tag{3}$$

para $i = 1, 2, ..., n$ e sujeitos a $\mathrm{Var}(\mathbf{U}_1) = \mathrm{Var}(\mathbf{V}_1) = 1$ (uma mudança de escala que não afeta os valores das correlações). Logo, temos que

$$\begin{aligned}
\mathsf{Cor}(\mathbf{U}_1, \mathbf{V}_1) &= \frac{\mathsf{Cov}(\mathbf{U}_1, \mathbf{V}_1)}{\sqrt{\mathsf{Var}(\mathbf{U}_1)}\sqrt{\mathsf{Var}(\mathbf{V}_1)}} \\
&= \mathsf{Cov}(\mathbf{U}_1, \mathbf{V}_1) \\
&= \mathsf{Cov}(\mathbf{a}_1^\top \mathbf{X}, \mathbf{b}_1^\top \mathbf{Y}) \\
&= \mathbf{a}_1^\top \mathbf{\Sigma}_{XY} \mathbf{b}_1.
\end{aligned}$$

Dessa forma, o problema de maximização se reduz à seguinte expressão

$$\max_{\mathbf{a},\mathbf{b}} \mathbf{a}_1^\top \mathbf{\Sigma}_{XY} \mathbf{b}_1, \tag{4}$$

sujeito a $\mathbf{a}_1^\top \mathbf{\Sigma}_{XY} \mathbf{a}_1 = \mathbf{b}_1^\top \mathbf{\Sigma}_{XY} \mathbf{b}_1 = 1$.

De forma similar, obtemos o segundo par de correlações, dado por $\mathbf{U}_2$ e $\mathbf{V}_2$ e assim segue até o par p, desde que $p < q$, pois são encontradas tantas funções canônicas quantos forem o menor número entre p e q. Note que a p-ésima função canônica deve ser não correlacionada com as $(p-1)$ funções canônicas anteriores.

Para obter os valores máximos das p correlações, é preciso derivar cada uma das p expressões, dadas por

$$\max_{\mathbf{a}_i,\mathbf{b}_i} \mathbf{a}_i^\top \mathbf{\Sigma}_{XY} \mathbf{b}_i, \tag{5}$$

para $i = 1, 2, ..., p$ com relação aos vetores $\mathbf{a}$ e $\mathbf{b}$ (existem diversos métodos que estimam os valores dos vetores $\mathbf{a}$ e $\mathbf{b}$, sendo o método dos multiplicadores de Lagrange o mais utilizado).

7 Técnicas multivariadas II (aprendizado supervisionado)

7.1 Modelo de regressão linear multivariado

7.1.1 Estrutura

Suponha que dispomos de m variáveis respostas, dadas por $\mathbf{Y}_1, \mathbf{Y}_2, ..., \mathbf{Y}_p$, no qual para cada uma dessas p variáveis está associado um grupo de variáveis explicativas, ou seja, para a variável $\mathbf{Y}_1$, por exemplo, temos o grupo de variáveis explicativas dadas por $\mathbf{X}_{11}, \mathbf{X}_{12}, ..., \mathbf{X}_{1k_1}$ e para para a variável reposta $\mathbf{Y}_p$, temos as variáveis explicativas $\mathbf{X}_{p1}, \mathbf{X}_{p2}, ..., \mathbf{X}_{pk_p}$.

Graybill (1976) definiu, portanto, que o modelo regressão multivariado consiste em ajustar um modelo de regressão para cada uma das m variáveis respostas e apresentou essa estrutura da seguinte forma:

$$\mathbf{Y}_{n\times m} = \mathbf{X}_{n\times(p+1)}\boldsymbol{\beta}_{(p+1)\times m} + \boldsymbol{\epsilon}_{n\times m}$$

sendo $\mathbf{Y}$ a matriz de matriz variável respostas (com as colunas sendo formadas pelas variáveis respostas e as linhas sendo formadas pela resposta do i-ésimo indivíduo), $\mathbf{X} = (\mathbf{X}_1, ..., \mathbf{X}_p)$ a matriz de planejamento (com as colunas sendo formadas pelas variáveis explicativas e as linhas sendo formadas pela valor da variável explicativa do i-ésimo indivíduo), $\beta = (\beta_0, ..., \beta_m)$ o vetor de coeficientes (com cada coluna sendo formada pelos coeficientes de cada variável resposta e $\epsilon = (\epsilon_0, ..., \epsilon_m)$ a matriz de erro (com as colunas sendo formadas pelo erro das variáveis respostas).

Representando matricialmente a estrutura do modelo anteriormente apresentado, temos a seguinte visão:

$$\begin{pmatrix} y_{11} & \dots & y_{11} \\ y_{21} & \dots & y_{2m} \\ \vdots & \ddots & \vdots \\ y_{n1} & \dots & y_{nm} \end{pmatrix} = \begin{pmatrix} 1 & x_{11} & \dots & x_{1p} \\ 1 & x_{21} & \dots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \dots & x_{np} \end{pmatrix} \begin{pmatrix} \beta_{01} & \dots & \beta_{0m} \\ \beta_{11} & \dots & \beta_{1m} \\ \vdots & \ddots & \vdots \\ \beta_{p1} & \dots & \beta_{pm} \end{pmatrix} + \begin{pmatrix} \epsilon_{11} & \dots & \epsilon_{1m} \\ \epsilon_{21} & \dots & \epsilon_{2m} \\ \vdots & \ddots & \vdots \\ \epsilon_{n1} & \dots & \epsilon_{nm} \end{pmatrix}$$

As principais suposições para o modelo de regressão multivariado são:

- $\mathbb{E}(\boldsymbol{\epsilon}_i) = \mathbf{0}$, $i = 1, 2, ..., n$
- $\mathrm{Var}(\boldsymbol{\epsilon}_i) = \boldsymbol{\Sigma}$, $i = 1, 2, ..., n$
- $\mathrm{Cov}(\boldsymbol{\epsilon}_i, \boldsymbol{\epsilon}_k) = \sigma^2_{ik}\mathbf{I}$, $k = 1, 2, ..., m$ e $i \neq k$.

7.1.2 Estimação dos parâmetros

Utilizando Mínimos Quadrados Ordinários (MQO), temos que

$$\min ||\mathbf{Y} - \mathbf{X}\beta||^2 = \min \sum_{i=1}^{n}\sum_{k=1}^{m}(y_{ij} - \beta_{0k} - \sum_{j=1}^{p}\beta_{jk}x_{ij})^2,$$

sendo $||\cdot||$ denotando a norma de Frobenius.

Assim, temos que:

$$\mathsf{MQO}(\beta) = ||\mathbf{Y} - \mathbf{Y}\beta||^2 = \mathsf{tr}(\mathbf{Y}^\top\mathbf{Y}) - 2\mathsf{tr}(\mathbf{Y}^\top\mathbf{Y}\beta) + \mathsf{tr}(\beta^\top\mathbf{X}^\top\mathbf{X}\beta).$$

Derivando, temos que

$$\frac{\partial \mathsf{MQO}(\beta)}{\partial \beta} = -2\mathbf{X}^\top\mathbf{Y} + 2\mathbf{X}^\top\mathbf{X}\beta.$$

Por sim, a solução por Mínimos Quadrados Ordinários é dada por:

$$\widehat{\beta} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{Y}.$$

7.1.3 Predições

Podemos fazer predições, utilizamos

$$\hat{\mathbf{Y}} = \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{Y}$$

7.1.4 Aplicação em dados reais

Considerando o conjunto de dados que descreve as características de diferentes modelos de automóveis (esses dados estão incluídos no *software* R com o nome *mtcars*), vamos apresentar cada detalhe dessa análise juntamente com os comandos do *software* R, considerando a modelagem por meio do modelo de regressão linear multivariado.

O banco de dados apresenta 11 variáveis (no caso, características) referentes a cada um dos 32 carros. Abaixo mostramos um resumo das 8 primeiras linhas desses dados.

```
> data(mtcars)
> head(mtcars, n=8)
                   mpg cyl  disp  hp drat    wt  qsec vs am gear carb
Mazda RX4         21.0   6 160.0 110 3.90 2.620 16.46  0  1    4    4
Mazda RX4 Wag     21.0   6 160.0 110 3.90 2.875 17.02  0  1    4    4
Datsun 710        22.8   4 108.0  93 3.85 2.320 18.61  1  1    4    1
Hornet 4 Drive    21.4   6 258.0 110 3.08 3.215 19.44  1  0    3    1
Hornet Sportabout 18.7   8 360.0 175 3.15 3.440 17.02  0  0    3    2
Valiant           18.1   6 225.0 105 2.76 3.460 20.22  1  0    3    1
Duster 360        14.3   8 360.0 245 3.21 3.570 15.84  0  0    3    4
Merc 240D         24.4   4 146.7  62 3.69 3.190 20.00  1  0    4    2
```

A seguir, podemos ver algumas medidas descritivas para as variáveis em estudo.

```
> summary(mtcars)
      mpg             cyl             disp             hp       
 Min.   :10.40   Min.   :4.000   Min.   : 71.1   Min.   : 52.0  
 1st Qu.:15.43   1st Qu.:4.000   1st Qu.:120.8   1st Qu.: 96.5  
 Median :19.20   Median :6.000   Median :196.3   Median :123.0  
 Mean   :20.09   Mean   :6.188   Mean   :230.7   Mean   :146.7  
 3rd Qu.:22.80   3rd Qu.:8.000   3rd Qu.:326.0   3rd Qu.:180.0  
 Max.   :33.90   Max.   :8.000   Max.   :472.0   Max.   :335.0  
      drat             wt             qsec             vs        
 Min.   :2.760   Min.   :1.513   Min.   :14.50   Min.   :0.0000  
 1st Qu.:3.080   1st Qu.:2.581   1st Qu.:16.89   1st Qu.:0.0000  
 Median :3.695   Median :3.325   Median :17.71   Median :0.0000  
 Mean   :3.597   Mean   :3.217   Mean   :17.85   Mean   :0.4375  
 3rd Qu.:3.920   3rd Qu.:3.610   3rd Qu.:18.90   3rd Qu.:1.0000  
 Max.   :4.930   Max.   :5.424   Max.   :22.90   Max.   :1.0000  
       am              gear            carb      
 Min.   :0.0000   Min.   :3.000   Min.   :1.000  
 1st Qu.:0.0000   1st Qu.:3.000   1st Qu.:2.000  
 Median :0.0000   Median :4.000   Median :2.000  
 Mean   :0.4062   Mean   :3.688   Mean   :2.812  
```

```
 3rd Qu.:1.0000   3rd Qu.:4.000   3rd Qu.:4.000
 Max.   :1.0000   Max.   :5.000   Max.   :8.000
```

Pelo fato de o objetivo desta aplicação ser a apresentação de como podemos usar o modelo linear multivariado na modelagem desse conjunto de dados, omitiremos detalhes sobre a descritiva e passaremos diretamente para o ajuste do modelo.

Para ser considerado um modelo multivariado, é necessário que o vetor resposta seja, na verdade, uma matriz resposta, com as colunas traduzindo o vetor de cada variável. Neste conjunto de dados, a matriz reposta é formada pelas variáveis:

- mpg: milhas / galão (EUA);
- disp: colindradas (polegadas cúbicas)
- hp: potência (em cavalos);
- wt: peso (1000 libras);

A matriz com as variáveis explicativas é formada pelas variáveis:

- cyl: número de cilindradas;
- am: transmissão (0 = automática, 1 = manual)
- carb: número de carburadores.

Dessa forma, vamos ajustar um modelo multivariado considerando todas as variáveis anteriormente apresentadas, por meio do *software* R.

No R, organizamos a matriz de respostas da seguinte forma:

```
> #Ajuste do modelo
> mtcars$cyl = factor(mtcars$cyl)
> Y = as.matrix(mtcars[,c("mpg","disp","hp","wt")])
```

Para ajustar um modelo multivariado, fazemos:

```
> model_mult = lm(Y ~ cyl + am + carb, data=mtcars)
> coef(model_mult)
                  mpg      disp         hp         wt
(Intercept) 25.320303 134.32487 46.5201421  2.7612069
cyl6        -3.549419  61.84324  0.9116288  0.1957229
cyl8        -6.904637 218.99063 87.5910956  0.7723077
am           4.226774 -43.80256  4.4472569 -1.0254749
carb        -1.119855   1.72629 21.2764930  0.1749132
```

Como também é de nosso interesse entender os resultados sobre os parâmetros estimados em cada um dos 4 modelos (para as variáveis mpg, disp, hp e wt), temos:

```
> #Coeficientes para cada variável resposta
> est.model.mult = summary(model_mult);est.model.mult
Response mpg :

Call:
```

```
lm(formula = mpg ~ cyl + am + carb, data = mtcars)

Residuals:
    Min      1Q  Median      3Q     Max
-5.9074 -1.1723  0.2538  1.4851  5.4728

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  25.3203     1.2238  20.690  < 2e-16 ***
cyl6         -3.5494     1.7296  -2.052 0.049959 *
cyl8         -6.9046     1.8078  -3.819 0.000712 ***
am            4.2268     1.3499   3.131 0.004156 **
carb         -1.1199     0.4354  -2.572 0.015923 *
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 2.805 on 27 degrees of freedom
Multiple R-squared:  0.8113,Adjusted R-squared:  0.7834
F-statistic: 29.03 on 4 and 27 DF,  p-value: 1.991e-09


Response disp :

Call:
lm(formula = disp ~ cyl + am + carb, data = mtcars)

Residuals:
    Min      1Q  Median      3Q     Max
-82.694 -21.442   0.254  26.500 111.779

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  134.325     21.836   6.152 1.42e-06 ***
cyl6          61.843     30.860   2.004   0.0552 .
cyl8         218.991     32.256   6.789 2.72e-07 ***
am           -43.803     24.086  -1.819   0.0801 .
carb           1.726      7.768   0.222   0.8258
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 50.05 on 27 degrees of freedom
Multiple R-squared:  0.858,Adjusted R-squared:  0.8369
F-statistic: 40.78 on 4 and 27 DF,  p-value: 4.537e-11


Response hp :

Call:
```

```
lm(formula = hp ~ cyl + am + carb, data = mtcars)

Residuals:
    Min      1Q  Median      3Q     Max 
-41.520 -17.941  -4.378  19.799  41.292 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept)  46.5201    10.4825   4.438 0.000138 ***
cyl6          0.9116    14.8146   0.062 0.951386    
cyl8         87.5911    15.4851   5.656 5.25e-06 ***
am            4.4473    11.5629   0.385 0.703536    
carb         21.2765     3.7291   5.706 4.61e-06 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 24.03 on 27 degrees of freedom
Multiple R-squared:  0.893,Adjusted R-squared:  0.8772 
F-statistic: 56.36 on 4 and 27 DF,  p-value: 1.023e-12


Response wt :

Call:
lm(formula = wt ~ cyl + am + carb, data = mtcars)

Residuals:
     Min       1Q   Median       3Q      Max 
-0.66317 -0.34384 -0.03802  0.12334  1.19083 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept)  2.76121    0.22133  12.476 1.01e-12 ***
cyl6         0.19572    0.31280   0.626  0.53675    
cyl8         0.77231    0.32695   2.362  0.02564 *  
am          -1.02547    0.24414  -4.200  0.00026 ***
carb         0.17491    0.07874   2.222  0.03489 *  
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.5073 on 27 degrees of freedom
Multiple R-squared:  0.7659,Adjusted R-squared:  0.7312 
F-statistic: 22.08 on 4 and 27 DF,  p-value: 3.484e-08


> #est.model.mult[[1]] #informação individual
> #est.model.mult[[2]] #informação individual
> #est.model.mult[[3]] #informação individual
```

```
> #est.model.mult[[4]] #informação individual
```

Avaliando a significância para cada modelo, ao nível de 5%, temos que:

- Para a variável resposta **mpg**, todas as variáveis explicativas foram significativas;
- Para a variável resposta **disp**, as variáveis explicativas cy16, am e carb não foram significativas;
- Para a variável resposta **hp**, as variáveis explicativas cy16 e am não foram significativas;
- Para a variável resposta **wt**, a variável explicativas cy16 não foi significativa.

Com base nisso, vamos avaliar o modelo somente com as variáveis explicativas am e carb, pois a cy16 só foi significativa em um modelo.

Utilizando os testes Wilk e Pillai, vamos comparar o modelo completo (3 variáveis explicativas) com o modelo reduzido (retirando a variável cyl).

Utilizando o teste de Wilk, temos:

```
> #Teste para novos modelos
> mvmod0 <- lm(Y ~ am + carb, data=mtcars)
> anova(mvmod, mvmod0, test="Wilks")
Analysis of Variance Table

Model 1: Y ~ cyl + am + carb
Model 2: Y ~ am + carb
  Res.Df Df Gen.var.   Wilks approx F num Df den Df    Pr(>F)
1     27      29.862
2     29  2   43.692 0.16395   8.8181      8     48 2.525e-07 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

Utilizando o teste de Pillai, temos:

```
> anova(mvmod, mvmod0, test="Pillai")
Analysis of Variance Table

Model 1: Y ~ cyl + am + carb
Model 2: Y ~ am + carb
  Res.Df Df Gen.var. Pillai approx F num Df den Df    Pr(>F)
1     27      29.862
2     29  2   43.692 1.0323   6.6672      8     50 6.593e-06 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

Uma forma detalhada para obter as estatísticas dos dois testes segue abaixo:

```
> Etilde <- n * SigmaTilde
> SigmaTilde1 <- crossprod(Y - mvmod0$fitted.values) / n
> Htilde <- n * (SigmaTilde1 - SigmaTilde)
> HEi <- Htilde %*% solve(Etilde)
> HEi.values <- eigen(HEi)$values
> c(Wilks = prod(1 / (1 + HEi.values)),
```

```
> Pillai = sum(HEi.values / (1 + HEi.values)))
    Wilks    Pillai
0.1639527 1.0322975
```

Para intervalos de confiança, podemos usar o seguinte comando, como exemplo, com os seguintes valores:

```
> # Intervalo de confiança
> newdata <- data.frame(cyl=factor(6, levels=c(4,6,8)), am=1, carb=4)
> predict(mvmod, newdata, interval="confidence")
       mpg     disp      hp       wt
1 21.51824 159.2707 136.985 2.631108
```

Para intervalos de predição, podemos usar o seguinte comando, como exemplo, com os seguintes valores:

```
> # Intervalo de predição
> newdata <- data.frame(cyl=factor(6, levels=c(4,6,8)), am=1, carb=4)
> predict(mvmod, newdata, interval="prediction")
       mpg     disp      hp       wt
1 21.51824 159.2707 136.985 2.631108
```

7.2 Análise de discriminante

A análise discriminante é uma técnica estatística usada para encontrar uma função que possa discriminar entre duas ou mais classes de objetos ou eventos, com base em um conjunto de variáveis preditoras.

É comumente usada em problemas de classificação, onde o objetivo é prever a classe de um novo objeto com base em suas características observadas.

Existem várias abordagens para a análise discriminante e, nesta seção, vamos estudar as seguintes:

- Análise Discriminante Linear (LDA, em inglês);
- Análise Discriminante Quadrática (QDA, em inglês);
- Naive Bayes.

Para todos os casos, utilizamos o chamado classificador gaussiano (baseado na regra de Bayes). O objetivo calcular a probabilidade de um objeto pertencer a uma determinada classe, dado seu conjunto de atributos.

Para tanto, são consideradas as probabilidades de cada classe, $p(\omega_i)$, que é chamada de probabilidade a *priori* e as densidades de probabilidade condicional de $\mathbf{x}$ com relação a cada uma das classes ω_i, $i = 1, 2, ..., c$, $p(\mathbf{x}|\omega_i)$, são conhecidos.

Assim, usando o teorema de Bayes, calculamos a probabilidade em questão fazendo:

$$p(\omega_i|\mathbf{x}) = \frac{p(\omega_i)p(\mathbf{x}|\omega_i)}{p(\mathbf{x})}, \tag{6}$$

sendo $p(\mathbf{x}) = \sum_{j=1}^{c} p(\omega_j)p(\mathbf{x}|\omega_j)$, para $i = 1, 2, ..., c$.

Podemos simplificar a expressão (6) ao desconsiderar o termo $p(\mathbf{x})$, pois não há influência dele na escolha da classe e, além disso, podemos considerar o uso do logaritmo, dado que esta é um função monotonicamente crescente e de fácil manipulação matemática.

Assim, chegamos na função discriminante basedo no classificador de Bayes:

$$g_i(\mathbf{x}) = \log[p(\mathbf{x}|\omega_i)] + \log[p(\omega_i)],$$

Portanto, para cada uma das três abordagens (LDA, QDA ou Naive Bayes), o que muda será a distribuição de probabilidade associada para $p(\mathbf{x}|\omega_i)$. Nas próximas seções, vamos detalhar as representações.

7.2.1 Análise Discriminante Linear (LDA)

Neste discriminante, assume-se que $p(\mathbf{x}|\omega_i) \sim \mathcal{N}(\mu_i, \Sigma)$, ou seja, considera que os atributos têm distribuição normal multivariada, com igual covariância entre os atributos das classes.

A função discriminante, para esse classificador, é dada por:

$$g_i(\mathbf{x}) = \frac{1}{2}\log|\Sigma| - \frac{1}{2}(\mathbf{x} - \mu_i)\Sigma^{-1}(\mathbf{x} - \mu_i) + \log[p(\omega_i)].$$

A regra de decisão desse classificador consiste em atribuir um conjunto de atributos $\mathbf{x}_k$ à uma classe ω_j, se

$$g_j(\mathbf{x}_k) > g_l(\mathbf{x}_k),$$

para todo $l \neq j$.

7.2.2 Análise Discriminante Quadrática (QDA)

Neste discriminante, assume-se que $p(\mathbf{x}|\omega_i) \sim \mathcal{N}(\mu_i, \Sigma_i)$, ou seja, considera que os atributos têm distribuição normal multivariada, com diferentes covariâncias entre os atributos das clases.

A função discriminante, para esse classificador, é dada por:

$$g_i(\mathbf{x}) = \frac{1}{2}\log|\Sigma_i| - \frac{1}{2}(\mathbf{x} - \mu_i)\Sigma_i^{-1}(\mathbf{x} - \mu_i) + \log[p(\omega_i)].$$

A regra de decisão desse classificador consiste em atribuir um conjunto de atributos $\mathbf{x}_k$ à uma classe ω_j, se

$$g_j(\mathbf{x}_k) > g_l(\mathbf{x}_k),$$

para todo $l \neq j$.

Um problema frequentemente associado a esse classificador está na inversão da matriz de covariância dos atributos, representada por Σ_i. Para verificar sua invertibildiade, sugere-se avaliar o valor do posto da matriz. Assim, a matriz será invertível se o seu posto for igual ao seu número de colunas (número de atributos).

Caso a matriz não seja de posto completo, não será possível calcular sua inversa. Como solução a esse problema, consideramos algumas variantes apresentadas na literatura, que serão brevemente descritas a seguir.

- **Variante Tikhonov para o classificador gaussiano:** utiliza uma constante de regularização λ, tal que $0 \leq \lambda \leq 1$, e a matriz identidade I, de dimensão $p \times p$, de forma a escrever a matriz de covariância no formato

$$\Sigma_i = \Sigma_i + \lambda I_p. \tag{7}$$

Essa pequena modificação na matriz de covariância (em geral assumimos um λ pequeno) é capaz de torná-la invertível, já que "desalinhamos"algum atributo que seja uma combinação linear de outro (lembrando dos conceitos de vetores linearmente dependente e linearmente independente).

Essa adição pode ser considerada como um incremento de um ruído na matriz de dados X que, por ser descorrelacionado, chamamos de ruído branco (chamado de *white-noise* no inglês).

- **Variante Friedman para o classificador gaussiano:** utiliza uma combinação da variante "white-noise"com a variante "pooled", da tal forma que a matriz de covariância da i-ésima classe é dada por

$$\Sigma_i = \frac{(1-\lambda)S_i + \lambda S_{\text{pool}}}{(1-\lambda)n_i + \lambda n}, \tag{8}$$

com $0 \leq \lambda \leq 1$, $S_i = n_i \Sigma_i$ e $S_{\text{pool}} = n\Sigma_{\text{pool}}$.

- **Variante pooled para o classificador gaussiano:** utiliza uma única matriz para todas as classes, de tal forma que essa matriz seja uma combinação das matrizes de covariância de cada classe. Dessa forma, temos

$$\Sigma_{\text{pool}} = \frac{1}{n}\sum_{i=1}^{n} n_i \Sigma_i, \tag{9}$$

sendo n o tamanho amostral considerando toda a amostra e n_i o tamanho amostra de cada classe.

Esta variante é útil para problemas em que as classes são desbalanceadas, ao evitar problemas numéricos resultantes de uma inversa mal-condicionada.

7.2.3 Naive Bayes

Neste discriminante, assume-se que $p(\mathbf{x}|\omega_i) \sim \mathcal{N}(\mu_i, \mathbf{I})$, ou seja, considera que os atributos têm distribuição normal multivariada, mas a a matriz de covariância é a matriz identidade, ou seja, utiliza somente a diagonal da matriz de covariância de cada classe.

Nessa abordagem a matriz sempre será invertível, porém, ao utilizá-la, estamos desconsiderando a possível existência de correlação entre os atributos de uma mesma classe, já que a matriz considera somente as variâncias de cada atributo.

A função discriminante, para esse classificador, é dada por:

$$g_i(\mathbf{x}) = \frac{1}{2}\log|\mathbf{I}| - \frac{1}{2}(\mathbf{x}-\mu_i)\mathbf{I}^{-1}(\mathbf{x}-\mu_i) + \log[p(\omega_i)].$$

A regra de decisão desse classificador consiste em atribuir um conjunto de atributos $\mathbf{x}_k$ à uma classe ω_j, se

$$g_j(\mathbf{x}_k) > g_l(\mathbf{x}_k),$$

para todo $l \neq j$.

7.3 Classificador linear de mínimos quadrados

Para esse classificador, consideramos a metodologia utilizada nos modelos de regressão linear na estimativa de seus parâmetros. Nessa abordagem, ao considerar a minimização dos erros entre o verdadeiro valor e o estimador, usamos o método do mínimos quadrados para chegar às expressões do vetor de parâmetros β.

Podemos fazer o uso dessa mesma abordagem para criar uma função discriminante para um classificador baseado num matriz de pesos $\mathbf{W}$, de tao forma que $\mathbf{y} = \mathbf{W}\mathbf{x}$. Essa matriz de pesos é obtida a partir da expressçao abaixo.

$$W = YX^\top(XX^\top)^{-1}, \tag{10}$$

sendo W a matriz de pesos; X a matriz de atributos; e Y os vetores referentes a cada classe.

8 Técnicas multivariadas III (aprendizado não supervisionado)

8.1 Análise de agrupamento (ou de cluster)

A análise de agrupamento, também conhecida como clustering, é uma técnica de aprendizado não supervisionado amplamente utilizada em diversas áreas, como reconhecimento de padrões, mineração de dados, bioinformática, entre outras.

O objetivo da análise de agrupamento é identificar grupos naturais ou subpopulações em um conjunto de dados, onde os objetos dentro de cada grupo são mais semelhantes entre si do que com objetos de outros grupos.

A análise de agrupamento é amplamente utilizada em diversas aplicações, como segmentação de mercado, análise de redes sociais, detecção de anomalias, classificação de documentos, entre outras.

A análise de agrupamento é uma ferramenta poderosa para explorar a estrutura de dados e identificar padrões subjacentes sem a necessidade de rótulos ou categorias pré-definidas. Com uma variedade de métodos disponíveis e uma ampla gama de aplicações, a análise de agrupamento continua a ser uma área ativa de pesquisa e desenvolvimento em ciência de dados e aprendizado de máquina.

Existem vários métodos de análise de agrupamento e, nesta seção, vamos estudar as seguintes abordagens:

- Agrupamento Hierárquico;
- K-Means;
- Mistura de Gaussianas.

8.1.1 Agrupamento Hierárquico

O agrupamento hierárquico é uma técnica que consiste em particionar os dados em uma ordem de prioridade entre os elementos de um conjunto. Geralmente é representada pelo gráfico chamado de dendrograma (que facilita a visualização da hierarquia entre os grupos).

Alguns do métodos mais comuns são:

- **Método de Ligação Simples:** utiliza a distância mínima entre os grupos e é conhecido por método dos vizinhos mais próximos;
- **Método da ligação completa:** utiliza a distância máxima entre os grupos e é conhecido por método dos vizinhos mais distantes;
- **Método média das distâncias:** utiliza a média das distâncias de todos os pares de elementos em que podem ser formados;
- **Método do centróide:** utiliza a média em cada grupo e somente depois desse processo é calculado a distância entre as médias, utilizando uma das distâncias apresentadas anteriormente;
- **Método de Ward:** utiliza o cálculo da distância entre dois grupos com a soma das distâncias ao quadrado.

8.1.2 K-Means

O K-Means é um algoritmo de agrupamento que divide um conjunto de dados não rotulados em k grupos distintos, onde k é um número predefinido de clusters. Cada cluster é representado por um ponto central, chamado de centróide, que é calculado como a média de todos os pontos pertencentes ao cluster.

O objetivo principal do K-Means é minimizar a variância intracluster, ou seja, a soma das distâncias quadráticas de todos os pontos dentro de um cluster em relação ao seu centróide. A ideia por trás do algoritmo é atribuir cada ponto ao centróide mais próximo, criando clusters compactos e bem separados entre si.

O algoritmo K-Means opera em algumas etapas principais:

- Definimos o número de clusters, k, e os centróides iniciais são escolhidos aleatoriamente a partir do conjunto de dados
- Cada unidade amostral é associado ao centróide mais próximo (geralmente calculado usando a distância euclidiana). Dessa forma, formam-se os clusters iniciais.
- Os centróides de cada cluster são recalculados com base na média dos pontos atribuídos a eles na etapa anterior.
- Todos os pontos são novamente associados ao centróide mais próximo, considerando os novos centróides calculados na etapa anterior.
- As etapas de atualização e reatribuição são repetidas iterativamente até que os centróides não se movam significativamente entre as iterações ou até que seja atingido um critério de parada predefinido.
- O algoritmo termina com os dados divididos em k clusters, e os centróides finais representam as posições centrais de cada cluster.

Este algoritmo é fácil de entender e implementar, tornando-o uma escolha popular para tarefas de agrupamento de dados. Pode ser computacionalmente eficiente, especialmente em grandes conjuntos de dados, sendo possível aplicar a conjuntos de dados de alta dimensionalidade, com resultados facilmente interpretados.

Entretanto, alguns pontos negativos são facilmente perceptíveis, tais como:

- o número de clusters, k, deve ser especificado antes da execução do algoritmo;
- escolher um valor adequado para k nem sempre é trivial e pode exigir conhecimento prévio do domínio ou técnicas de validação;
- a escolha inicial dos centróides pode afetar o resultado final, podendo levar a soluções subótimas ou diferentes;
- pode ser sensível a outliers, pois eles podem distorcer a posição dos centróides e afetar o agrupamento geral assume que os clusters têm uma forma esférica e de tamanhos aproximadamente iguais, podendo levar a problemas quando os clusters têm formas complexas ou tamanhos muito diferentes.

8.1.3 Mistura de Gaussianas

Sugestão para seminário!

8.1.4 Coeficientes de concordância

- Correspondência múltipla;
- Rogers e Tanimoto;
- Russell e Rao;
- Kulzynsk;
- Sokal e Sneath;
- Hamann;
- Jaccard;
- Dice- Sorensen;
- Simpsom;

8.1.5 Métodos de escolha do número de grupos

- Coeficiente de correlação cofenética;
- Método Elbow;
- Análise do comportamento do nível de similaridade.

9 Técnicas multivariadas IV (tópicos extras)

9.1 Equações Estruturais

9.1.1 Conceitos iniciais

A Modelagem por Equações Estruturais (SEM, em inglês) é uma técnica estatística multivariada que utiliza os conceitos de Análise Fatorial Confirmatória e Modelos de Regressão para modelar e analisar relacionamentos entre variáveis latentes e observadas.

Essa estrutura permite a inserção de várias variáveis dependentes (vários desfechos), diferentes tipos de variáveis (binárias, discretas, contínuas), inclusão de modelagem dos erros de medidas e grande flexibilidade no trabalho de dados faltantes. Todas essas análises podem ser feitas tanto no contexto transversal quanto no contexto longitudinal.

O modelo consiste em duas partes principais:

- **Modelo de medição:** mostra como as vaiáveis de medição representam as variáveis latentes (está relacionada a Análise Fatorial Confirmatória);
- **Modelo estrutural:** mostra como as variáveis latentes estão associadas umas com as outras.

9.1.2 Símbolos e terminologias

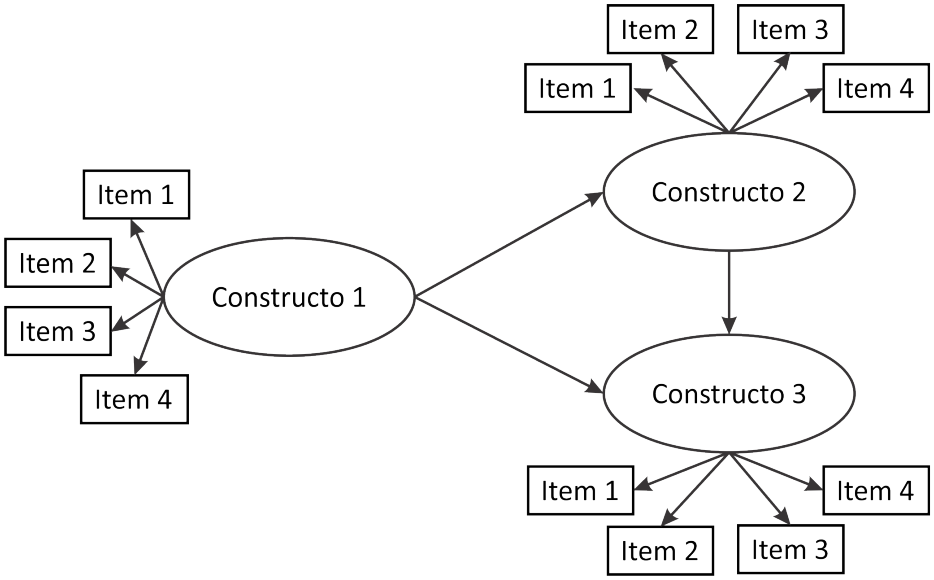

Figura 3: Símbolos e terminologias para SEM.

9.1.3 Estrutura

Dentro da abordagem das EE, precisamos seguir as seguintes etapas:

- Especificação do modelo: definir como será a estrutura de modelagem;
- Identificação do modelo: graus de liberdade positivo (número de informações disponível é mais do que número de informações a serem estimadas);

- Estimação dos coeficientes do modelo: método de Mínimos Quadrados Parciais (PLS), o método de Máxima Verossimilhança (ML) e o método de Mínimos Quadrados Ordinários (OLS)
- Avaliação do modelo: índices de adequação, de ajuste, de adequação de ajuste, dentre outros;
- Reespecificação: mudar a estrutura, se necessário.

9.1.4 Aplicação

As equações estruturais são aplicadas em uma ampla gama de áreas de pesquisa, como avaliação de medidas, modelagem de processos causais, teste de teorias e desenvolvimento de escalas de medição. Por exemplo, na psicologia, a EE é frequentemente usada para investigar modelos de personalidade, inteligência e motivação.

As equações estruturais são uma ferramenta poderosa para modelar e testar hipóteses em contextos complexos. Ao integrar modelos de medição e modelos estruturais, as EE permitem uma compreensão mais profunda dos relacionamentos entre variáveis latentes e observadas. Com sua flexibilidade e capacidade de lidar com modelos complexos, as equações estruturais continuam a ser uma técnica importante em diversas áreas de pesquisa e prática.